POLITEKNIK NEGERI MALANG • JURUSAN TEKNOLOGI INFORMASI

Program Studi D-IV Teknik Informatika • Pembelajaran Mesin (Machine Learning) Semester V

MODUL BELAJAR LENGKAP UTS: ALGORITMA KNN

Teori Fundamental, Formula Metrik, Simulasi Hitungan Manual, & Implementasi Kasus PBL

Disusun Khusus Menghadapi Evaluasi Tengah Semester (UTS) • PBL Kelompok 04 TI-3C

1. Fondasi & Karakteristik Kunci K-Nearest Neighbors (KNN)

K-Nearest Neighbors (KNN) adalah algoritma pembelajaran terawasi (*supervised learning*) serbaguna yang dapat menangani permasalahan **klasifikasi** (menentukan label kategori) dan **regresi** (memprediksi nilai kontinu numerik). Prediksi dilakukan berdasarkan prinsip kedekatan jarak geometris terhadap tetangga-tetangga terdekatnya pada ruang fitur.

1. Paradigma Non-Parametrik

KNN **tidak mengasumsikan bentuk distribusi data tertentu** (seperti distribusi normal Gaussian pada Naive Bayes). Model membentuk batas keputusan (*decision boundary*) secara bebas dan fleksibel mengikuti sebaran data asli.

2. Lazy Learner (Instance-Based)

KNN **tidak memiliki fase pelatihan model (training phase) eksplisit**. Model hanya menyimpan/menghafal seluruh data latih ke memori RAM. Seluruh kalkulasi jarak baru dilakukan ketika data uji (query) masuk saat inferensi.

🎯 **TABEL KOMPARASI KRUSIAL UTS: Eager Learner vs Lazy Learner**

Karakteristik Pembanding	Eager Learner (SVM, Naive Bayes, Random Forest)	Lazy Learner (K-Nearest Neighbors)
Waktu Pelatihan (Training)	Lama / Berat (Membangun bobot hyperplane / pohon)	Instan / Sangat Cepat $O(1)$ (Hanya menyimpan data)
Waktu Inferensi (Prediksi)	Sangat Cepat $O(1)$ s/d $O(d)$ (Evaluasi fungsi matematis)	Lambat $O(N \times d)$ (Menghitung jarak ke seluruh N data)
Konsumsi Memori RAM	Ringan (Hanya menyimpan parameter/aturan pohon)	Berat (Harus menyimpan seluruh dataset ke RAM)
Penanganan Data Baru	Harus me-retrain seluruh model jika ada data baru	Tinggal menambahkan baris data baru ke tabel dataset

2. Prinsip Kerja & 5 Langkah Standar Algoritma KNN

1. **Tentukan Parameter Nilai k:** Tetapkan berapa banyak jumlah tetangga terdekat yang akan digunakan (misal $k = 3$ atau $k = 5$).
2. **Hitung Jarak ke Seluruh Data Latih:** Hitung jarak antara vektor sampel uji X_{uji} dengan seluruh sampel latih $(X_1, X_2, ..., X_N)$ menggunakan metrik jarak yang dipilih.
3. **Urutkan Nilai Jarak (Sorting):** Urutkan seluruh jarak dari yang bernilai terkecil (paling dekat) ke nilai terbesar (paling jauh).
4. **Ambil k Tetangga Terdekat:** Pilih k data latih teratas yang memiliki jarak paling minimum terhadap X_{uji}.
5. **Keluarkan Keputusan Prediksi:**
   - **Untuk Klasifikasi:** Terapkan **Majority Voting** (kelas terbanyak/modus yang muncul di antara k tetangga).
   - **Untuk Regresi:** Hitung **Nilai Rata-rata** (mean) dari target kontinu dari k tetangga tersebut.

3. Formula Metrik Jarak (Distance Metrics) Matematis

Ketepatan klasifikasi KNN sangat bergantung pada metrik jarak geometris yang digunakan untuk mengukur derajat kemiripan antar-sampel data:

📐 RUMUS METRIK JARAK WAJIB KUASAI UNTUK UTS

1. Jarak Euclidean (L_2 Norm • Derajat Minkowski p = 2 • Jarak Garis Lurus):

$$d(x, y) = \sqrt{\left[\sum_{i=1}^{n} (x_i - y_i)^2\right]} = \sqrt{\left[(x_1 - y_1)^2 + (x_2 - y_2)^2 + \ldots + (x_n - y_n)^2\right]}$$

Sifat: Paling sering digunakan sebagai default. Namun rentan terhadap outlier karena selisih angka dikuadratkan.

2. Jarak Manhattan / City Block (L_1 Norm • Derajat Minkowski p = 1 • Jarak Kisi Grid):

$$d(x, y) = \sum_{i=1}^{n} |x_i - y_i| = |x_1 - y_1| + |x_2 - y_2| + \ldots + |x_n - y_n|$$

Sifat: Menghitung jumlah pergeseran absolut tegak lurus. Jauh lebih tahan (robust) terhadap pencilan (outlier).

3. Jarak Minkowski (Generalisasi Metrik Berordo p):

$$d(x, y) = \left[\sum_{i=1}^{n} |x_i - y_i|^p\right]^{1/p}$$

Catatan Scikit-Learn: Diatur melalui parameter `metric='minkowski'`. Jika `p=1` menjadi Manhattan; jika `p=2` menjadi Euclidean.

4. Mengapa Feature Scaling Menjadi Syarat Mutlak pada KNN?

⚠️ PERINGATAN KONSEP: EFEK DOMINASI BESARAN FITUR

KNN menghitung selisih numerik secara langsung di setiap dimensi. Jika ada fitur dengan rentang nilai ribuan dan fitur lain berentang desimal, **fitur bernilai besar akan mendominasi hasil kuadrat jarak secara mutlak**, membuat fitur kecil menjadi tidak berguna.

Teknik Scaling	Formula Matematis	Karakteristik & Rekomendasi Penggunaan
StandardScaler (Z-Score) *(Dipakai pada PBL Kelompok 4)*	$z = (x - \mu) / \sigma$ Rata-rata μ = 0, Standar Deviasi σ = 1	Sangat disarankan saat data memiliki sebaran bervariasi atau mengandung outlier. Tidak membatasi nilai pada batas kaku.
MinMaxScaler (Normalisasi)	$x' = (x - x_{min}) / (x_{max} - x_{min})$ Memetakan seluruh nilai tepat ke rentang [0, 1]	Bagus ketika batas bawah dan batas atas data sudah pasti (misal intensitas kanal warna RGB 0 s/d 255).

Bukti Numerik Efek Scaling:

Misal ada 2 fitur daun pisang: **Luas Lesi Daun** (X_1 rentang 10 - 4000 mm^2) dan **Skor Eksentrisitas** (X_2 rentang 0.1 - 0.9).
Jarak Euclidean tanpa scaling antara dua sampel:
• Selisih Luas: $(2500 - 2000)^2 = 500^2 = 250.000$
• Selisih Eksentrisitas: $(0.85 - 0.15)^2 = 0.70^2 = 0.49$
• Jarak Total: √(250000 + 0.49) = √250000.49 ≈ **500.0005**
Kesimpulan: Kontribusi fitur X_2 hanya 0.49 / 250000.49 ≈ 0.00019%. Fitur X_2 praktis **diabaikan sama sekali** hanya karena skala satuannya lebih kecil! Oleh karena itu, `StandardScaler` wajib dipasang sebelum KNN.

5. Pemilihan Nilai Hyperparameter k & Bias-Variance Tradeoff

Penentuan nilai *k* adalah inti dari optimasi model KNN karena langsung mengendalikan kompromi antara *underfitting* dan *overfitting*.

Nilai k Sangat Kecil (Contoh: k = 1)

- **Low Bias, High Variance (OVERFITTING):** Model terlalu sensitif menangkap fluktuasi lokal.
- Batas keputusan (*decision boundary*) sangat rumit, berliku-liku, dan terfragmentasi.
- Sangat rentan terhadap **noise** atau titik anomali salah label (outlier). Satu titik rusak dapat mengacaukan prediksi tetangga di dekatnya.
- Akurasi pada data latih sempurna (100%), namun gagal menggeneralisasi data uji baru.

Nilai k Sangat Besar (Contoh: k = N)

- **High Bias, Low Variance (UNDERFITTING):** Model terlalu kaku dan mengabaikan pola lokal.
- Batas keputusan menjadi sangat datar dan terlalu halus.
- Jika nilai *k* = *N* (seluruh ukuran data latih), maka model akan **selalu memprediksi kelas mayoritas mutlak** untuk input titik apa pun di ruang fitur.
- Kemampuan diskriminasi antar-pola fitur menjadi hilang.

💡 3 ATURAN EMAS (RULES OF THUMB) MENENTUKAN NILAI k PADA UTS

1. **Gunakan Bilangan Ganjil pada Masalah Biner:** Jika terdapat 2 kelas (misal Sehat vs Sakit), pilihlah *k* berupa bilangan ganjil ($k=3, 5, 7, 9$) agar tidak pernah terjadi hasil seri (*tie vote*).
2. **Pendekatan Akar Jumlah Data (Rule of Thumb):** Nilai awal praktis dapat diestimasi dengan k ≈ √N (di mana N adalah jumlah data latih).
3. **Validasi Silang (K-Fold Cross Validation):** Cara formal dan paling akurat adalah menguji rentang nilai *k* menggunakan `GridSearchCV` dan memilih *k* dengan skor validasi tertinggi.

6. Mekanisme Pembobotan Tetangga & Penanganan Tie (Seri)

Opsi Parameter `weights`	Cara Kerja Pembobotan Suara	Kelebihan & Kasus Penggunaan
Uniform Weights `weights='uniform'` *(Default Scikit-Learn)*	Setiap tetangga terdekat memiliki bobot suara yang **sama persis** ($w_i = 1$).	Sederhana, namun tetangga yang berada di batas luar memiliki hak voting yang sama dengan tetangga yang menempel persis di query.
Distance Weights `weights='distance'`	Bobot suara tetangga **berbanding terbalik dengan jaraknya**: $$w_i = 1 / d(x, x_i)$$	Tetangga yang posisinya sangat dekat memberikan pengaruh prediksi jauh lebih kuat dibanding tetangga yang posisinya jauh.

Strategi Mengatasi Hasil Seri (Tie Breaking):

Jika pada klasifikasi multi-kelas terjadi perolehan suara seimbang (misal pada $k=4$, terdapat 2 suara untuk Kelas A dan 2 suara untuk Kelas B):

- **Metode 1 (Bobot Invers Jarak):** Jumlahkan nilai bobot $\sum (1 / d_i)$ untuk masing-masing kelas. Kelas dengan akumulasi bobot jarak terbesar menjadi pemenang.
- **Metode 2 (Reduksi Nilai k):** Turunkan nilai tetangga menjadi $k - 1$ hingga diperoleh suara mayoritas tunggal.
- **Metode 3 (Prioritas Terdekat):** Berikan keputusan kepada kelas yang dimiliki oleh tetangga peringkat ke-1 (paling dekat mutlak).

7. Simulasi Perhitungan Manual Langkah Demi Langkah (Tipe Soal Hitungan UTS)

SOAL HITUNGAN RESMI UTS PEMBELAJARAN MESIN

Diberikan data latih 6 sampel daun tanaman dengan 2 fitur: **Intensitas Kuning (X_1)** dan **Luas Lesi Bercak (X_2)**. Kelas target adalah **Sehat (0)** atau **Sakit (1)**. Terdapat data uji baru $X_{uji} = (6, 5)$. Tentukan kelas prediksi untuk X_{uji} menggunakan KNN dengan: **(a) k = 3** dan **(b) k = 5** menggunakan metrik Jarak Euclidean!

ID	X_1 (Kuning)	X_2 (Lesi)	Proses Hitung Euclidean: $\sqrt{((6 - X_1)^2 + (5 - X_2)^2)}$	Jarak (d)	Urutan	Label Kelas
D1	2	3	$(6-2)^2 + (5-3)^2 = 4^2 + 2^2 = 16 + 4 = 20$	$\sqrt{20} \approx$ **4.47**	Peringkat 5	Sehat (0)
D2	3	6	$(6-3)^2 + (5-6)^2 = 3^2 + (-1)^2 = 9 + 1 = 10$	$\sqrt{10} \approx$ **3.16**	Peringkat 3	Sehat (0)
D3	5	4	$(6-5)^2 + (5-4)^2 = 1^2 + 1^2 = 1 + 1 = 2$	$\sqrt{2} \approx$ **1.41**	**Peringkat 1**	Sehat (0)
D4	7	8	$(6-7)^2 + (5-8)^2 = (-1)^2 + (-3)^2 = 1 + 9 = 10$	$\sqrt{10} \approx$ **3.16**	Peringkat 4	Sakit (1)
D5	8	7	$(6-8)^2 + (5-7)^2 = (-2)^2 + (-2)^2 = 4 + 4 = 8$	$\sqrt{8} \approx$ **2.83**	**Peringkat 2**	Sakit (1)
D6	9	9	$(6-9)^2 + (5-9)^2 = (-3)^2 + (-4)^2 = 9 + 16 = 25$	$\sqrt{25} =$ **5.00**	Peringkat 6	Sakit (1)

Pengurutan Jarak dari Terkecil ke Terbesar (Ranked Neighbors):

1. **Data D3:** $d = 1.41$ • Label = **Sehat (0)**
2. **Data D5:** $d = 2.83$ • Label = **Sakit (1)**
3. **Data D2:** $d = 3.16$ • Label = **Sehat (0)**
4. **Data D4:** $d = 3.16$ • Label = **Sakit (1)**
5. **Data D1:** $d = 4.47$ • Label = **Sehat (0)**
6. **Data D6:** $d = 5.00$ • Label = **Sakit (1)**

(a) Keputusan untuk Nilai k = 3

Ambil 3 tetangga terdekat: **D3 (Sehat), D5 (Sakit), D2 (Sehat)**.
• Suara Sehat (0) = 2 suara.
• Suara Sakit (1) = 1 suara.
Mayoritas: Sehat (0) memiliki 2 dari 3 suara.
→ **Hasil Prediksi: SEHAT (0)**.

(b) Keputusan untuk Nilai k = 5

Ambil 5 tetangga terdekat: **D3, D5, D2, D4, D1**.
• Suara Sehat (0) = 3 suara (D3, D2, D1).
• Suara Sakit (1) = 2 suara (D5, D4).
Mayoritas: Sehat (0) memiliki 3 dari 5 suara.
→ **Hasil Prediksi: SEHAT (0)**.

BAGAIMANA JIKA SOAL REGRESI? (CONTOH VARIAN UTS)

Jika targetnya adalah angka kontinu (misal Tingkat Kerusakan Daun %: D3=15%, D5=45%, D2=20%):
Prediksi untuk k = 3 adalah nilai rata-ratanya: $\hat{y} = (15 + 45 + 20) / 3 = 80 / 3 =$ **26.67%**.

8. Bedah Implementasi Kode Python & Scikit-Learn (Proyek PBL EcoPlant AI)

Pada proyek PBL Kelompok 4 (EcoPlant AI), KNN digunakan untuk mendeteksi 4 kategori penyakit daun pisang berdasarkan 48 fitur histogram warna RGB. Berikut arsitektur pipeline resminya:

```
from sklearn.pipeline import make_pipeline
from sklearn.impute import SimpleImputer
from sklearn.preprocessing import StandardScaler
from sklearn.neighbors import KNeighborsClassifier
from sklearn.model_selection import StratifiedKFold, GridSearchCV
from sklearn.metrics import accuracy_score, classification_report, confusion_matrix

# 1. Pipeline Terintegrasi: Menjamin Bebas Kebocoran Data (Data Leakage)
pipeline_knn = make_pipeline(
    SimpleImputer(strategy="median"),      # Tangani missing values dengan median
    StandardScaler(),                      # Standarisasi z-score (WAJIB untuk model metrik jarak)
    KNeighborsClassifier(
        n_neighbors=5,                     # Jumlah tetangga k=5
        metric="minkowski",                # Metrik Minkowski
        p=2,                               # Derajat p=2 -> Ekuivalen Euclidean Distance
        weights="uniform"                  # Bobot suara seragam
    )
)

# 2. Pelatihan & Prediksi pada Data Uji Independen (80:20 Stratified Split)
pipeline_knn.fit(X_train, y_train)
y_pred = pipeline_knn.predict(X_test)

# 3. Evaluasi Metrik Klasifikasi
print("Akurasi:", accuracy_score(y_test, y_pred))
print(classification_report(y_test, y_pred, target_names=["Cordana", "Healthy", "Pestalotiopsis", "Sigatoka"]))
```

> 🧠 **PERTANYAAN SIDANG/UTS: Mengapa Harus Memakai `make_pipeline` ?**
>
> Jika standarisasi `StandardScaler().fit_transform(X)` dilakukan pada seluruh dataset sebelum train-test split, maka nilai rata-rata (μ) dan standar deviasi (σ) dari data uji akan ikut terhitung ke dalam data latih. Ini adalah kesalahan fatal yang disebut **Data Leakage (Kebocoran Data)**. Dengan `Pipeline`, fungsi `fit()` hanya menghitung statistik dari X_{latih}, dan X_{uji} hanya ditransformasikan secara murni.

Otomatisasi Hyperparameter Tuning dengan GridSearchCV

```
# Mencari konfigurasi nilai k dan metrik terbaik secara sistematis
param_grid = {
    'kneighborsclassifier__n_neighbors': [3, 5, 7, 9, 11, 15],
    'kneighborsclassifier__weights': ['uniform', 'distance'],
    'kneighborsclassifier__p': [1, 2] # 1: Manhattan, 2: Euclidean
}

cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)
grid = GridSearchCV(pipeline_knn, param_grid, cv=cv, scoring='f1_macro', n_jobs=-1)
grid.fit(X_train, y_train)

print("Kombinasi Parameter Terbaik:", grid.best_params_)
print("Skor Validasi Terbaik (Macro F1):", grid.best_score_)
```

> 💡 **PENJELASAN PARAMETER UTAMA SCIKIT-LEARN:**
>
> - `n_neighbors` : Menentukan nilai k (jumlah tetangga terdekat).
> - `weights` : `'uniform'` (suara sama rata) atau `'distance'` (suara terbobot invers jarak).
> - `algorithm` : `'auto'`, `'ball_tree'`, `'kd_tree'`, atau `'brute'`.
> - `p` : Parameter daya Minkowski (1 = Manhattan, 2 = Euclidean).

9. Evaluasi Metrik & Komparasi Model (Konteks PBL Kelompok 4)

Pada eksperimen empiris dataset daun pisang (1.361 citra valid, 4 kelas) dengan ekstraksi 48 fitur histogram warna RGB, hasil evaluasi performa ke-4 model ditabulasikan sebagai berikut:

Model Algoritma	Arsitektur & Penanggung Jawab	Akurasi	Presisi	Recall	F1-Macro
Random Forest	Ensemble Bagging 200 Trees (Siti Mutmainah)	**81,32%**	**0,7942**	**0,8032**	**0,7983**
SVM (RBF Kernel)	Margin Hyperplane C=1.0 (Fattah Haidar Aly)	75,46%	0,7313	0,7290	0,7291
KNN (k = 5)	**Instance-Based Euclidean (Afrizal Kusuma W.)**	**71,43%**	**0,6721**	**0,6851**	**0,6739**
Gaussian Naive Bayes	Probabilistik Bayes (Andi Otani Dipo Y.)	54,58%	0,5378	0,4957	0,5024

🎯 **BEDAH ANALITIS KINERJA KNN (POTENSI PERTANYAAN PENGUJI UTS)**

- **Mengapa KNN Unggul Jauh dari Naive Bayes (71,43% vs 54,58%)?** Karena Naive Bayes memiliki asumsi ketat bahwa setiap fitur bersifat independen. Pada citra biologis daun pisang, kanal warna R, G, dan B memiliki korelasi natural yang sangat kuat. KNN tidak memiliki asumsi independensi sehingga mampu membaca kombinasi warna secara simultan melalui metrik jarak.
- **Mengapa KNN Dikalahkan oleh Random Forest (71,43% vs 81,32%)?** KNN menderita fenomena **Curse of Dimensionality** pada vektor 48 dimensi. Dalam ruang 48 dimensi yang renggang (*sparse*), jarak geometris antar-titik menjadi kurang diskriminatif. Sebaliknya, Random Forest mempartisi fitur secara hierarkis per threshold tanpa bergantung jarak ruang global.
- **Analisis Confusion Matrix KNN:** KNN sering salah mengklasifikasikan bercak *Pestalotiopsis* fase awal sebagai daun sehat (*Healthy*) karena sebaran spektrum histogram warnanya sangat berdekatan di ruang fitur geometris.

10. Analisis SWOT Lengkap Algoritma KNN

Kelebihan (Strengths)

- Konsep sangat sederhana, intuitif, dan transparan.
- Tidak ada asumsi distribusi data (Non-Parametrik).
- Waktu pelatihan instan $O(1)$ (tidak ada iterasi epoch).
- Sangat adaptif menangani batas keputusan multi-kelas non-linear yang kompleks.
- Penambahan data baru mudah tanpa perlu proses re-training.

Kelemahan (Weaknesses) & Solusinya

- **Inferensi Lambat:** Kompleksitas O(N × d) → *Solusi: Gunakan KD-Tree atau Ball-Tree.*
- **Boros RAM:** Harus menyimpan semua sampel → *Solusi: Data pruning / condensing.*
- **Curse of Dimensionality:** Kinerja anjlok pada dimensi tinggi → *Solusi: Reduksi dimensi PCA / Seleksi Fitur.*
- **Sensitif Skala:** Wajib standardisasi `StandardScaler`.

11. Bank Soal Latihan & Kunci Jawaban Konseptual UTS

Soal 1: Mengapa KNN dikategorikan sebagai "Lazy Learner" dan apa dampaknya jika model ini di-deploy langsung pada aplikasi mobile smartphone?

Jawaban: KNN disebut *lazy learner* karena menunda seluruh komputasi hingga fase prediksi (tidak membentuk formula model di awal). Jika di-deploy ke smartphone, ponsel harus menyimpan seluruh dataset latih ke memori RAM lokal dan menghitung jarak ke seluruh data setiap kali mengambil foto, yang mengakibatkan proses inferensi lambat (lag) dan boros baterai ponsel.

Soal 2: Apa akibatnya jika nilai k = 1 diterapkan pada dataset yang memiliki label salah (noisy labels)?

Jawaban: Model akan mengalami *overfitting* ekstrem (low bias, high variance). Karena $k=1$ hanya melihat 1 tetangga terdekat mutlak, maka setiap titik uji baru yang berada di sekitar sampel anomali/noise tersebut akan langsung salah diklasifikasikan mengikuti label salah tersebut.

Soal 3: Titik A = (3, 7) dan B = (6, 3). Hitung jarak Euclidean dan Manhattan kedua titik tersebut!

Jawaban:

- **Euclidean:** $d = \sqrt{(6-3)^2 + (3-7)^2} = \sqrt{3^2 + (-4)^2} = \sqrt{9 + 16} = \sqrt{25} = \mathbf{5.0}$
- **Manhattan:** $d = |6-3| + |3-7| = |3| + |-4| = 3 + 4 = \mathbf{7.0}$

Soal 4: Bagaimana mekanisme KNN menghasilkan output jika digunakan untuk kasus REGRESI?

Jawaban: Pada regresi, output bukan berupa voting mayoritas kelas, melainkan nilai rata-rata (mean) dari target kontinu k tetangga terdekat: $\hat{y} = (1/k) \sum y_i$, atau menggunakan rata-rata terbobot jarak: $\hat{y} = (\sum w_i y_i) / (\sum w_i)$.

Soal 5: Sebutkan struktur data yang dapat menurunkan kompleksitas pencarian KNN dari O(N) menjadi O(log N)!

Jawaban: Menggunakan struktur pohon partisi ruang spasial seperti **KD-Tree (k-dimensional tree)** atau **Ball-Tree**.

✅ CHECKLIST AKHIR PERSIAPAN SEBELUM MASUK RUANG UTS

- Kuasai perbedaan mendasar *Instance-Based* vs *Model-Based* dan *Lazy* vs *Eager Learner*.
- Bisa menghitung cepat rumus Jarak Euclidean ($p=2$) dan Manhattan ($p=1$) tanpa salah aritmatika.
- Ingat langkah standar: hitung jarak → urutkan ascending → ambil top-k → mayoritas suara (atau rata-rata target).
- Pahami efek k kecil (overfitting, batas rumit) vs k besar (underfitting, batas datar).
- Hafal alasan ilmiah mengapa `StandardScaler` dan `Pipeline` wajib digunakan.
- Kuasai alasan mengapa KNN berada di peringkat ke-3 di bawah Random Forest pada proyek EcoPlant AI.