Pemahaman dan Pra Pengolahan Data

RTI235004 – Pembelajaran Mesin

Tim Pengembang RPS

Outline

- Pengenalan Data
- Analisis Data Eksploratori
- Pra Pengolahan Data

Pengenalan Data

Apa itu data?

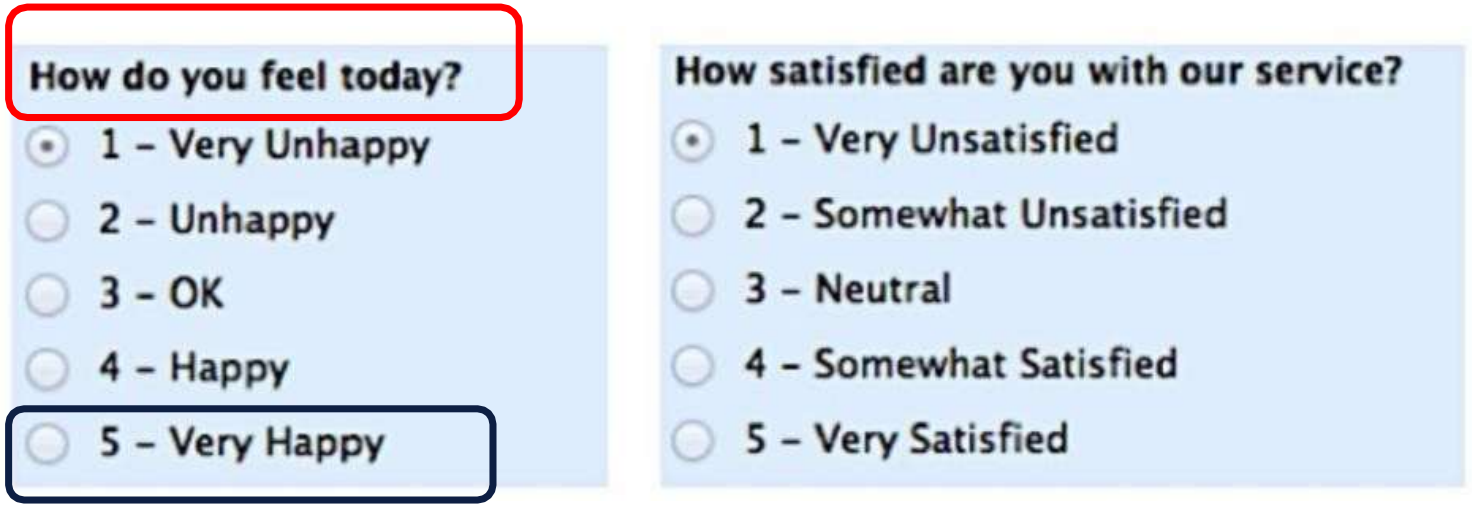
- Nilai asli dari variabel (Illowsky, dkk., 2022)
- Sebuah fakta, statistik, informasi, dan sering berbentuk angka (numerik) (OECD, 2008)
- Satuan dari sebuah informasi
- Perlu ditransformasikan untuk menjadi sebuah informasi
- Dalam stastistika disebut juga sebagai sebuah variabel

Pengertian Data

Data dalam pembelajaran mesin adalah representasi informasi mentah yang dikumpulkan dari berbagai sumber, kemudian diproses dan digunakan sebagai dasar untuk melatih model agar mampu mengenali pola, membuat prediksi, atau mengambil keputusan tanpa instruksi eksplisit.

Data vs. Variabel

Variabel



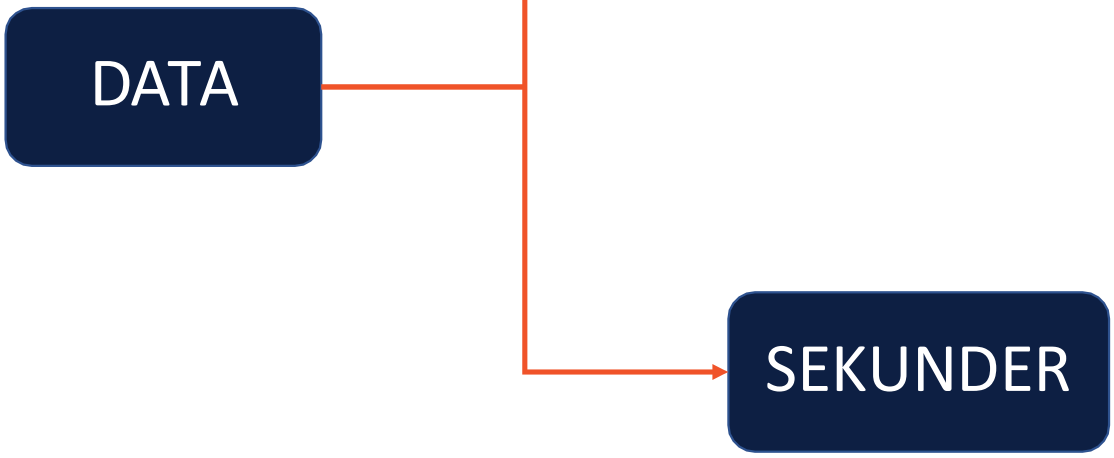
Data

Data vs. Variabel – Contoh Lain

Voluntariness of use	1	2	3	4	5	6	7
My participation on Facebook during the demonstration were voluntarily							

Constructs							
	1	2	3	4	5	6	7
Performance expectancy							
PE01: I would find Facebook useful by providing the news at the moment about the demonstration and what is going on right now. (Increasing of awareness) PE02: Through using Facebook can I publish demonstration events to the world more quickly than traditional media PE03: Through using digital media such Facebook, my physical participations will increase (Facebook motivate me to go down to street and contribute in demonstration)							
Effort expectancy	1	2	3	4	5	6	7
EE01: My comments which I have written about demonstration more clear and expression while it organized by one page "Khalid Saied Page" which concern one subject EE02: It would be easy to know which pages concern about demonstration events. EE03: I would find Facebook easy to use and flexible and no restrictions to join or leaving the page.							
Social influence	1	2	3	4	5	6	7
SI01: participants in demonstration who have influence (relatives) my behavior think that I should use Facebook. SI02: participants in demonstration who are important to me (non- relatives) think that I should use Facebook. SI03: In general, the community encourages to use Facebook and share the information as much as can.							
Facilitating conditions:	1	2	3	4	5	6	7
FC01: I have necessary resources to use Facebook. (The government allows and control the internet traffic during the demonstration) FC02: I have necessary knowledge to use Facebook. FC03: The Facebook is not the only method which deals with during the demonstration FC04: I do not need assistance to deal with Facebook functions.							
Behavioral intention to use the system	1	2	3	4	5	6	7
BI01: I will work on publishing demonstration news on Facebook pages. BI02: I will continue to publish demonstration events without stop							

Bagaimana cara mendapatkan data?



- Data yang dikumpulkan oleh peneliti sendiri
- Belum tentu valid

- Data yang dikumpulkan oleh peneliti lain
- Biasanya telah divalidasi oleh peneliti lain melalui studi sejenis

Bagaimana cara mendapatkan data primer?

Registrasi

- Menekankan pada proses pencatatan sebuah kondisi (biasanya oleh sebuah institusi. Contoh: Angka kelahiran)

Sensus

- Pengambilan data yang cenderung pada populasi → Jumlah data sangat besar

Survey

- Pengambilan data fokus pada jumlah yang lebih kecil → sampel

Eksperimen

- Data didapatkan dari hasil percobaan

Observasi

- Data didapatkan dari hasil pengamatan → Peneliti tidak terlibat langsung dalam obyek yang diamati untuk melakukan pengukuran

Bagaimana cara mendapatkan data sekunder?

- Publikasi Ilmiah
- Publikasi Institusi
- Portal Data
- Dan lainnya

Analisis Data Eksploratori (EDA)

Pengertian EDA

- Analisis dataset berdasarkan berbagai metode numerik dan alat grafis.
- Mengeksplorasi data untuk menemukan pola, tren, struktur dasar, penyimpangan dari tren, anomali, dan struktur yang tidak biasa.
- Pendekatan ini memudahkan penemuan hal-hal yang tidak terduga sekaligus mengonfirmasi hal-hal yang diharapkan. 12
- Definisi lain: Sebuah pendekatan/filsafat dalam analisis data yang menggunakan berbagai teknik (sebagian besar bersifat grafis).

Tujuan EDA

Tujuan Utama: Memahami data dan pola-pola yang ada sebelum analisis lebih lanjut.

Poin-Poin Penting:

🔍 **Memahami data**: Jenis, distribusi, dan karakteristik dasar
📈 **Menemukan pola & tren**: Hubungan antar variabel
⚠️ **Mendeteksi anomali/outlier**: Nilai yang tidak biasa atau kesalahan data
✅ **Memeriksa asumsi data**: Distribusi, linearitas, dll.
🎯 **Membantu pengambilan keputusan**: Menentukan langkah analisis atau model yang tepat

Analisis Data Eksploratori vs Analisis Data Konfirmatori

Aspek	EDA (Analisis Data Eksploratif)	CDA (Analisis Data Konfirmatori)
Tujuan	Menemukan pola dan wawasan dari data	Mengkonfirmasi atau menguji hipotesis
Hipotesis awal	Tidak ada hipotesis di awal	Dimulai dengan hipotesis
Fokus utama	Eksplorasi dan pemahaman data	Pengujian hipotesis nol
Metode yang digunakan	Metode grafis (visualisasi)	Model statistik
Contoh teknik	Histogram, box plot, scatter plot, heatmap	Uji t, uji chi-square, ANOVA, regresi
Sifat analisis	Deskriptif dan terbuka	Inferensial dan terfokus
Kapan digunakan	Tahap awal analisis data	Setelah EDA, untuk menguji temuan lebih lanjut

Langkah-langkah EDA

🎯 **Buat pertanyaan penelitian yang jelas**

🔄 **Restrukturisasi data**

Buat variabel baru dari yang ada
Hitung rate/persentase
Buat variabel dummy untuk kategori

📊 **Analisis awal**

Gunakan grafik dan statistik deskriptif
Pahami struktur, hubungan, anomali, perilaku tak terduga

🔎 **Identifikasi masalah potensial**

Variabel pengganggu, interaksi, multikolinearitas

❌ **Tangani data hilang**

🔧 **Tentukan kebutuhan transformasi**

📝 **Tentukan hipotesis** sesuai pertanyaan penelitian

Konfirmasi EDA

✅ **Verifikasi hipotesis** melalui analisis statistik
📊 **Tarik kesimpulan** dan **sajikan hasil secara rapi**

Klasifikasi EDA

Klasifikasi Exploratory Data Analysis (EDA)

- **Klasifikasi 1:** Non-grafis vs Grafis

  Non-grafis: Hitung statistik ringkasan
  Grafis: tampilkan data dalam diagram/gambar

- **Klasifikasi 2:** Univariat vs Multivariat

  Univariat: Analisis satu variabel per waktu
  Multivariat: Analisis dua atau lebih variabel sekaligus
  - Biasanya **bivariat** (dua variabel)
  - Kadang lebih dari dua variabel

💡 **Tips:** Lakukan **EDA univariat** sebelum **EDA multivariat**

Contoh 1

Data dari *Places Rated Almanac* (Boyer & Savageau, 1985)

329 kawasan metropolitan di AS

9 Variabel Utama:

- 🌤️ **Iklim**
- 🏠 **Biaya perumahan**
- 🏥 **Kesehatan & lingkungan**
- 🚨 **Kejahatan**
- 🚌 **Transportasi**
- 🎓 **Pendidikan**
- 🎨 **Seni & budaya**
- ⚽ **Rekreasi**
- 💰 **Prospek ekonomi pribadi**

📍 **Tambahan:** Garis lintang & bujur kota

Pertanyaan Analisis Data

- 🌤️ Bagaimana **iklim** terkait **lokasi**?
- 📊 Apakah terdapat **klaster** dalam data (tanpa lokasi)?
- 🏙️ Apakah kota-kota yang berdekatan **mirip**?
- 💰🚨 Hubungan antara **prospek ekonomi** & **kejahatan**?
- ❓ Pertanyaan lain yang bisa dieksplorasi

Contoh 2

Pertanyaan Penelitian Kanker Payudara

💉 Metode Pengobatan

Apakah ada pengobatan dengan **tingkat kelangsungan hidup lebih tinggi**?

👩 Karakteristik Pasien

Dapatkah pengobatan tertentu disarankan untuk wanita dengan **karakteristik khusus**?

⚖️ Perbedaan Antar Pasien

Apakah ada perbedaan **tingkat kelangsungan hidup**?
Contoh: wanita kulit putih vs wanita kulit hitam pada **tahap penyakit yang sama**

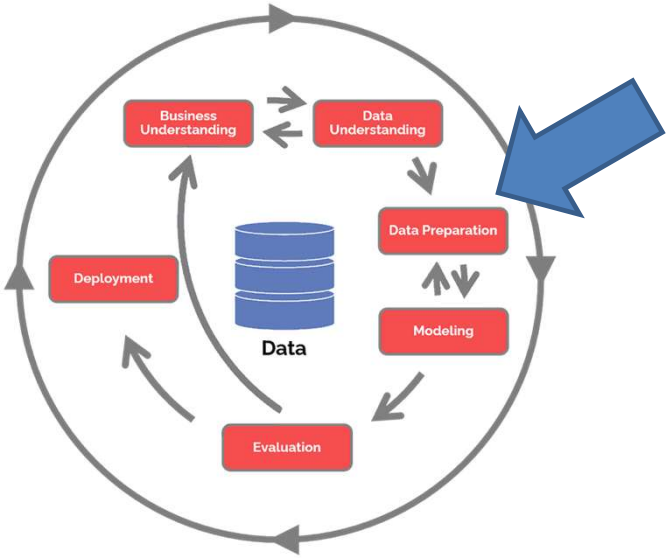
Pra Pengolahan Data

jti.polinema.ac.id
Pembelajaran Mesin

Persiapan Data (Data Preparation)

Definisi:

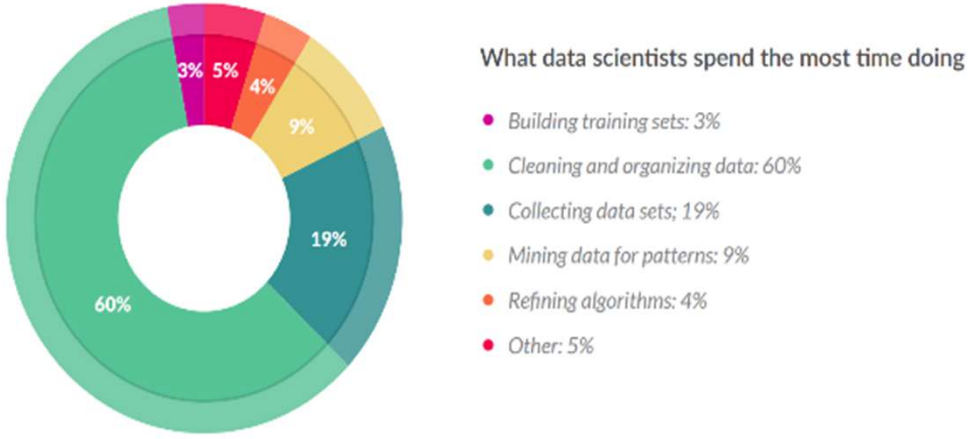
Proses yang melibatkan koneksi ke satu atau banyak sumber data yang berbeda, membersihkan data kotor, memformat ulang atau merestrukturisasi data, dan akhirnya menggabungkan data ini untuk digunakan untuk analisis.
Transformasi data mentah menjadi format yang mudah dipahami
Menemukan data yang relevan untuk disertakan dalam aplikasi analitik shg memberikan informasi yang dicari oleh analis atau pengguna bisnis
Langkah pra-pemrosesan yang melibatkan pembersihan, transformasi, dan konsolidasi data.

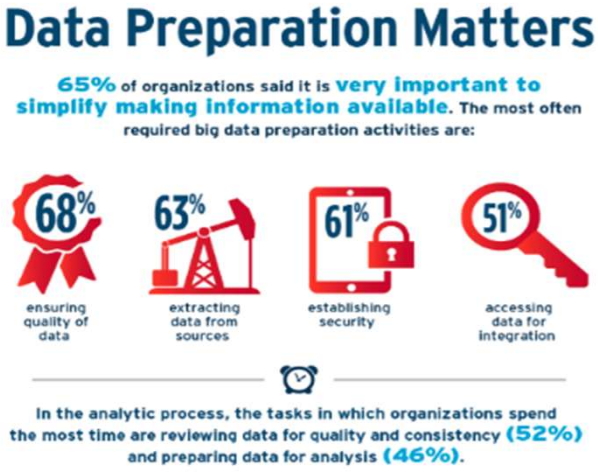


Istilah lain: Data Pre-processing, Data Manipulation, Data Cleansing/ Normalization

Persiapan Data

- 60–80% waktu data scientist dihabiskan untuk pra-pengolahan data (Forbes, Crowdflower 2016)
- Data berasal dari berbagai sumber dan format:
  - Terstruktur (database, tabel)
  - Semi-terstruktur (JSON, XML, log file)
  - Tidak terstruktur (teks, gambar, audio, video)
- Kualitas model prediktif bergantung pada kualitas data Garbage In, Garbage Out (GIGO)

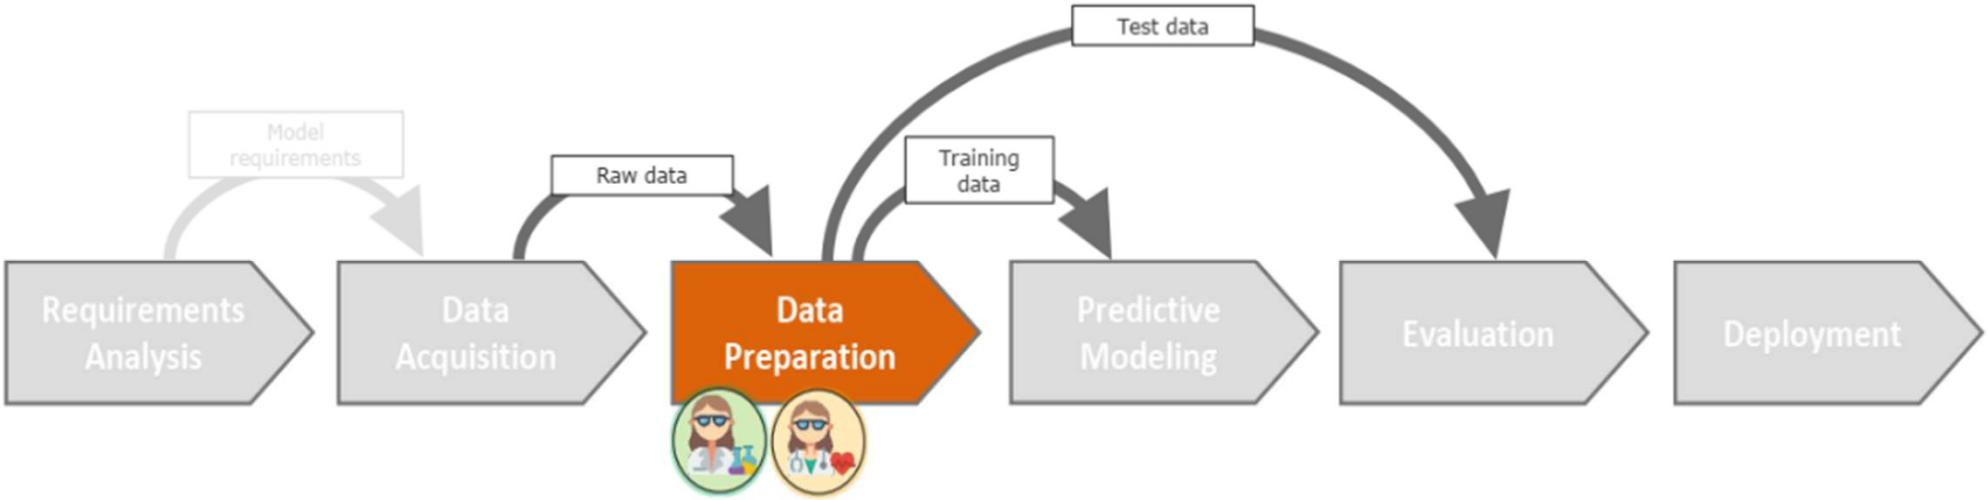




Mengapa Persiapan Data itu Penting?

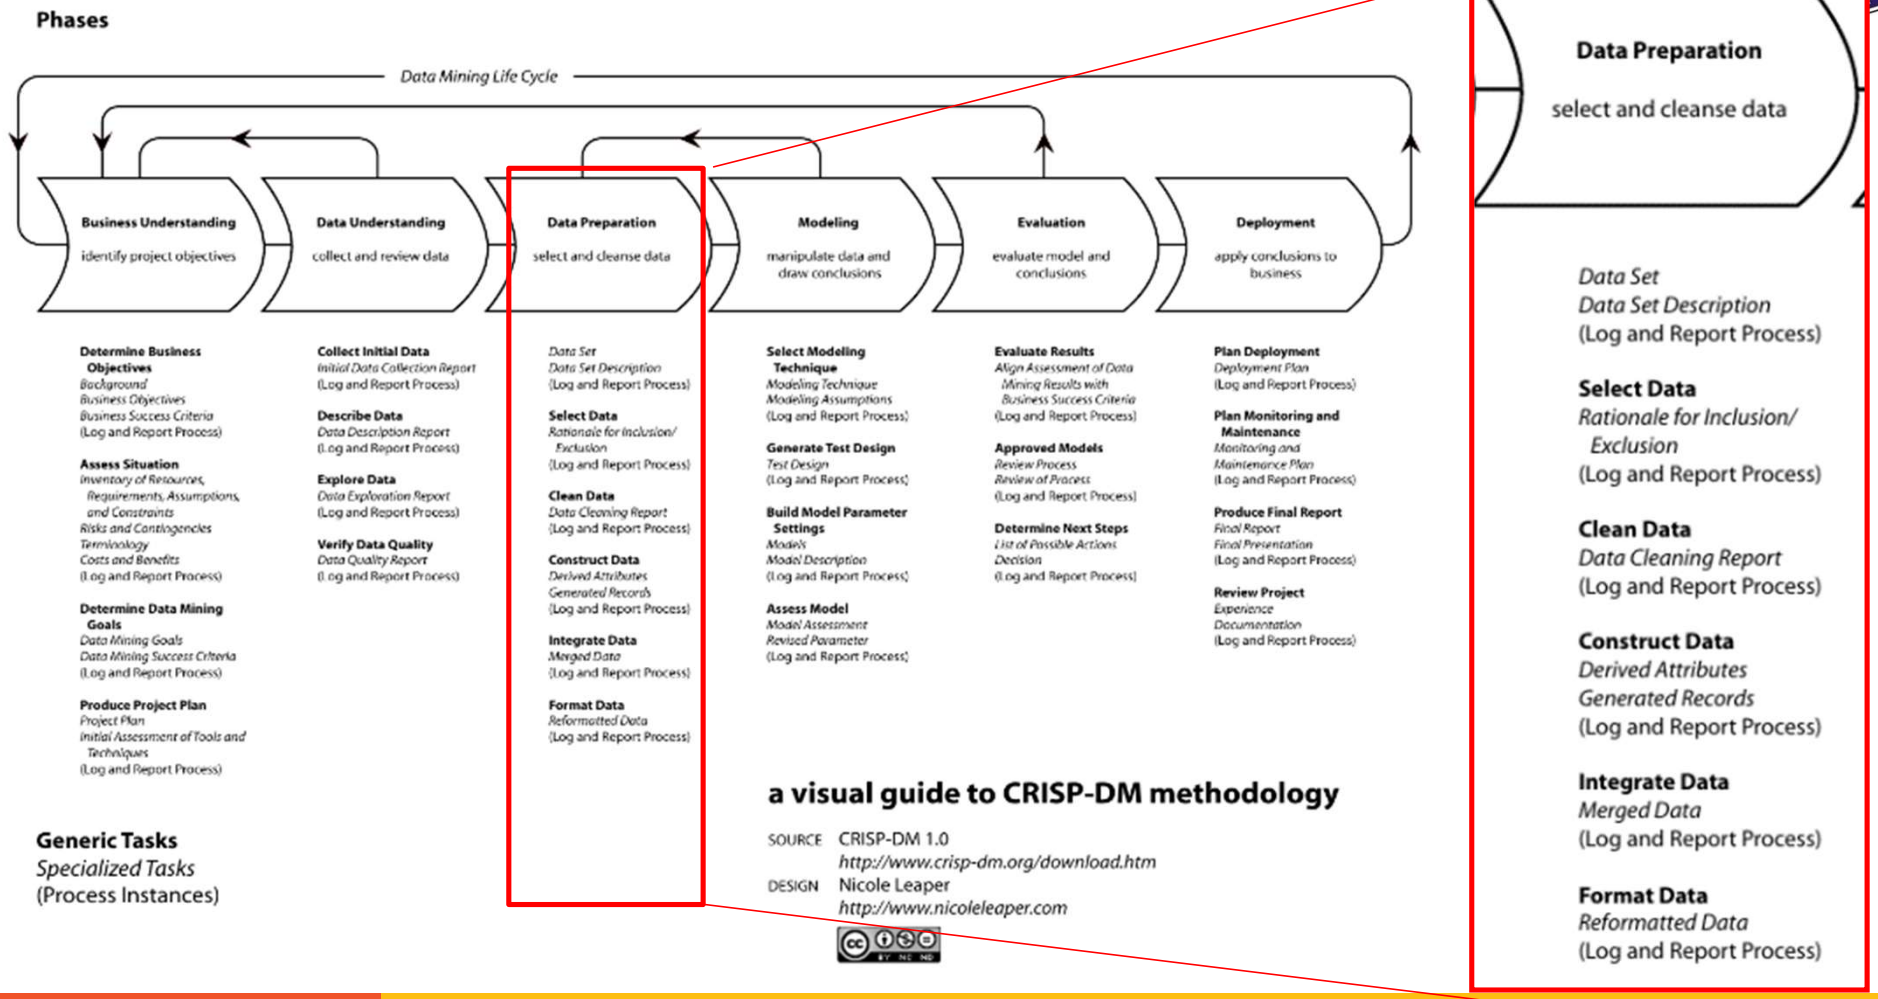
- data perlu diformat sesuai dengan software yang digunakan
- data perlu disesuaikan dengan metode data sain yang digunakan
- data real-world cenderung ‘kotor’:
  - tidak komplit: kurangnya nilai attribute, kurangnya atribut tertentu/penting, hanya berisi data agregate. misal: pekerjaan=”” (tidak ada isian)
  - noisy: memiliki error atau outlier. misal: Gaji=”-10”, Usia=”222”
  - tidak konsisten: memliki perbedaan dalam kode dan nama. misal : Usia= “32” TglLahir=”03/07/2000”; rating “1,2,3” -- > rating “A, B, C”
  - kolom dan baris yang saling bertukar
  - banyak variabel dalam satu kolom yang sama

Tantangan dalam Tahap Persiapan Data



- Memakan Waktu Lama
- Porsi Teknis yang Dominan
- Data yang Tersedia Tidak Akurat atau Jelas/Tidak Langsung Pakai
- Data tidak Balance Saat Pengambilan Sampel
- Rentan akan Error

CRISP-DM vs Data Preparation



Tahapan Utama dalam Persiapan Data

Pembersihan Data (Data Cleaning)	Pengurangan Data (Data Reduction)	Transformasi dan Diskretisasi (Data Transformation and Discretization)	Integrasi Data (Data Integration)
• Penanganan data kosong (missing value) • Penghalusan data kotor (noisy data) • Penanganan pencilan (outliers) • Penangaan inkonsistensi data	• Pengurangan dimensi data • Pengurangan jumlah data • Kompresi data	• Normalisasi (Normalization) • Concept hierarchy generation	• Integrasi banyak database / file

PEMBERSIHAN DATA (DATA CLEANING)

Data Kosong (Missing Data)

Data kosong (missing value) dapat disebabkan oleh:

- Perangkat / peralatan yang tidak berfungsi
- Inkonsistensi data akibat pelanggaran integritas referensial
- Data tidak disimpan karena kesalahpahaman (kesalahan manusia)
- Data dianggap tidak penting untuk dimasukkan (tidak wajib diisi)
- Perubahan / penghapusan data
- Kerusakan data akibat kegagalan perangkat lunak database.
- dll

Jenis Data Kosong (Missing Data)

Missing Completely At Random (MCAR)

Contoh: Tabel data dicetak tanpa nilai yang hilang. Seseorang secara tidak sengaja menjatuhkan beberapa tinta di atasnya sehingga beberapa sel tidak dapat dibaca lagi. Di sini, kita dapat mengasumsikan bahwa **nilai yang hilang mengikuti distribusi yang sama dengan nilai yang diketahui**.

Missing At Random (MAR)

Data kosong disebabkan karena kesengajaan responden tidak mengisi data (contoh isian pendapatan/gaji, tidak semua responden mau mengisi)

Missing Not At Random (MNAR)

Mekanisme data hilang yang tidak terdistribusi secara random.
Contoh: suhu tidak terekam oleh sensor saat berada pada suhu kurang dari 5^0 C

Contoh Data Kosong (Missing Data)

Dataset: MissingDataSet.csv

ExampleSet (11 examples, 0 special attributes, 15 regular attributes) View Filter (11 / 11): all

Row No.	Gender	Race	Birth_Year	Marital_Stat..	Years_on_I..	Hours_Per..	Preferred_B..	Preferred_S..	Preferred_E..	Read_News	Online_Sho..	Online_Ga..	Facebook	Twitter	Other_Soci..
1	M	White	1972	M	8	1	Firefox	Google	Yahoo	Y	N	N	Y	N	?
2	M	Hispanic	1981	S	14	2	Chrome	Google	Hotmail	Y	N	N	Y	N	?
3	F	African Amer	1977	S	6	2	Firefox	Yahoo	Yahoo	Y	Y	?	Y	N	?
4	F	White	1961	D	8	6	Firefox	Google	Hotmail	N	Y	N	N	Y	?
5	M	White	1954	M	2	3	Internet Expl	Bing	Hotmail	Y	Y	N	Y	N	?
6	M	African Amer	1982	D	15	4	Internet Expl	Google	Yahoo	Y	N	Y	N	N	?
7	M	African Amer	1981	D	11	2	Firefox	Google	Yahoo	?	Y	?	Y	Y	LinkedIn
8	M	White	1977	S	3	3	Internet Expl	Yahoo	Yahoo	Y	?	?	Y	99	LinkedIn
9	F	African Amer	1969	M	6	2	Firefox	Google	Gmail	N	Y	N	N	N	?
10	M	White	1987	S	12	1	Safari	Yahoo	Yahoo	Y	?	Y	Y	N	MySpace
11	F	Hispanic	1959	D	12	5	Chrome	Google	Gmail	Y	N	N	Y	N	Google+

Penanganan Data Kosong (Missing Data)

Abaikan (hapus data / record yang mengandung nilai kosong)

Bukan pilihan jika nilai kosongnya banyak, dan jika dihapus dapat mengurangi jumlah data secara signifikan.

Isi nilai kosong secara manual

Tidak efektif jika datanya banyak

Imputasi nilai secara otomatis.

Imputasi adalah mengganti nilai/data yang hilang (missing value, NaN, blank, dll) dengan nilai pengganti.

Teknik Imputasi Otomatis

Data Numerik:

- Imputasi mean atau median.
- Imputasi nilai suka-suka (arbitrary).
- Imputasi nilai/data ujung (end of tail).

Data Nominal (Kategorikal):

- Imputasi kategori yang sering muncul.
- Tambah kategori yang hilang.

Imputasi Mean atau Median

Kelebihan:

- Mudah dan cepat.
- Bekerja efektif untuk dataset numerik berukuran kecil.
- Cocok untuk variabel numerik.
- Cocok untuk data missing completely at random (MCAR).
- Dapat digunakan dalam produksi (mis. dalam model deployment).

Kekurangan:

- Tidak memperhitungkan korelasi antar fitur, berfungsi pada tingkat kolom.
- Kurang akurat.
- Tidak memperhitungkan probabilitas/ketidakpastian.
- Tidak cocok utk >5% missing data.
- Mendistorsi variansi dan distribusi variabel asal/orijinal serta covariant variabel sisa data.





Imputasi Nilai Suka-suka (Arbitrary)

Kelebihan:

Asumsi data tidak missing at random.
Mudah dan cepat diterapkan untuk melengkapi dataset.

Kekurangan:

Mendistorsi variansi dan distribusi variabel asal/orijinal serta covariant variabel sisa data.
Membentuk outlier (jika nilai arbitrer berada di akhir distribusi).
Semakin besar NA maka semakin besar distorsi.
Hindari memilih nilai arbitrer yang mendekati nilai mean atau median.



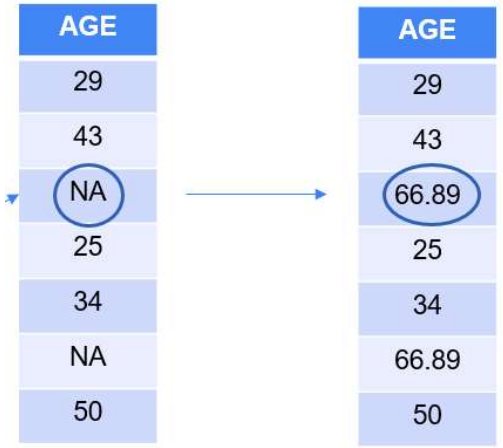
Imputasi Nilai Akhir (End of Tail)

Kelebihan:

Mirip dengan imputasi suka-suka.
Cocok untuk variabel numerik.

Ketentuan khusus:

Dalam memilih nilai arbitrer:
Jika variabel berdistribusi normal, maka nilai arbiter = mean + 3 * std deviasi.
Jika variabelnya skew, maka gunakan aturan IQR proximity (IQR = 75th Quantile – 25th Quantile; Upper limit = 75th Quantile + IQR ×3; Lower limit = 25th Quantile - IQR ×3).
Hanya digunakan pada data latih (training set).



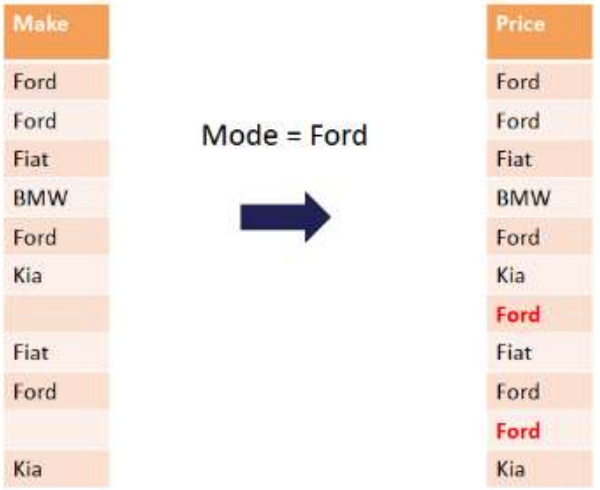
Imputasi Frequent Category (Modus)

Kelebihan:

Cocok untuk data dengan missing at random.
Mudah dan cepat diterapkan.
Cocok utk data yang memiliki skew
Dapat digunakan dalam produksi (mis. dalam model deployment).

Kelemahan:

Mendistorsi relasi label dengan frekuensi tertinggi vs variabel lain.
Menghasilkan over-representation jika banyak data yang missing.



Imputasi Sampel Acak (Random Sample)

Kelebihan:

Cocok untuk data missing at random.
Ganti missing value dengan nilai lain dalam distribusi yang sama dari variabel asli.
Mudah dan cepat.
Mempertahankan varians dari variabel.

Gender	Age
Male	29
Male	NA
NA	43
Female	25
Male	34
NA	50
Female	NA

Gender	Age
Male	29
Male	34
Female	43
Female	25
Male	34
Male	50
Female	25

Kekurangan:

Randomness.
Membutuhkan memori besar untuk deployment karena perlu untuk menyimpan data latih yg asli untuk ekstraksi nilai.

Teknik Imputasi Lainnya

Imputasi Nilai Nol/Konstanta

Mudah
Dapat memunculkan bias dalam data.

Imputasi dengan K-NN

Lebih akurat dibanding teknik lainnya
Komputasi besar

Imputasi Regresi: Deterministik

Mengganti missing value dengan prediksi yang tepat dari model regresi.

Imputasi Regresi: Stokastik

Mengatasi masalah dalam imputasi regresi deterministic dengan menambahkan fitur “random error” sehingga reproduksi korelasi X-Y lebih tepat.

Penanganan Data Kotor (Noisy Data)

Data Kotor: memuat error atau memuat outliers (data yang secara nyata berbeda dengan data-data yang lain)
Contoh jenis/bentuk data kotor:

- Data tidak konsisten
- Data pencilan (outlier)
- Data tidak utuh (incomplete)
- Data ganda (duplicate)

Jenis Data Kotor	Penjelasan	Contoh
Data tidak konsisten	Data yang tidak sesuai dengan format atau aturan tertentu	Tanggal lahir: *12/03/2000* vs *2000-03-12* ; Kota: *Surabaya* vs *Sby*
Data pencilan (*outlier*)	Data yang nilainya jauh berbeda dibandingkan data lain	Umur siswa: *15, 16, 15, 17, 99*
Data tidak lengkap	Data yang sebagian atribut atau nilainya hilang	Nama: *Andi* , Alamat: *–(kosong)* , No. HP: *08123456789*
Data duplikat	Data yang tercatat lebih dari satu kali	Entri 1: *Budi, 20 th, Malang* ; Entri 2: *Budi, 20 th, Malang*

Teknik Penanganan Data Kotor (Noisy Data)

Binning

- Data diurutkan dan dikelompokkan, lalu lakukan penghalusan (smoothing)
- Dapat diterapkan pada data kategorik dan numerik.
- Model lebih robust dan mencegah overfitting

Regression

- Penghalusan berdasarkan fungsi regresi

Clustering

- Mendeteksi dan menghilangkan pencilan (outlier)

Kombinasi penanganan oleh komputer dan manual

- Memerlukan campur tangan manusia dalam menangani data kotor

PENGURANGAN DATA (DATA REDUCTION)

41

Strategi Pengurangan Data (Data Reduction)

Data Reduction

Sebisa mungkin mengurangi ukuran / jumlah data, tetapi tidak mengurangi makna data dan hasil analisisnya.

Mengapa dilakukan Data Reduction?

Ukuran database yang terlalu besar

Analisis keseluruhan data yang kompleks memerlukan waktu yang lama

Strategi Data Reduction

- Pengurangan Dimensi (Dimensionality Reduction)
  - Feature Extraction
  - Feature Selection
- Pengurangan Jumlah (Numerosity Reduction)
  - Regression and Log-Linear Models
  - Histograms, clustering, sampling

1. Pengurangan Dimensi Data (Dimensionality Reduction)

Dimensi data = jumlah atribut dataset

- Semakin besar dimensi data, sebaran data semakin besar dan sulit dianalisis.
- Semakin besar dimensi data, hubungan dan jarak antar titik data semakin tidak berarti.
- Semakin besar dimensi data, semakin lama proses analisis datanya.

Tujuan pengurangan dimensi data:

- Menghindari efek buruk besarnya dimensi data
- Membantu menghilangkan fitur / atribut yang tidak relevan (tidak penting)
- Mengurangi waktu proses analisis (mining) data.
- Mempermudah visualisasi dan interpretasi data.

Teknik pengurangan dimensi data:

- Feature Extraction: Wavelet transforms, Principal Component Analysis (PCA)
- Feature Selection: Filter, Wrapper, Embedded

Seleksi Atribut

Cara lain untuk mengurangi dimensi data

Atribut Redundan

Menggandakan sebagian besar atau seluruh informasi yang terkandung dalam satu atau lebih atribut lainnya

Contoh: harga beli suatu produk dan jumlah pajak penjualan yang dibayarkan

Atribut Tidak Relevan

Tidak mengandung **informasi yang berguna** untuk tugas data mining yang sedang dilakukan

Contoh: ID siswa sering kali tidak relevan untuk tugas memprediksi IPK siswa

ID Siswa	Nama	Lama Bermain Game (jam/minggu)	Total Jam (bulan)	Nilai UTS	Nilai Tugas	IPK
1	Andi	10	40	78	80	3.25
2	Budi	15	60	85	88	3.50
3	Citra	20	80	60	65	2.75
4	Dewi	5	20	90	92	3.80

2. Reduksi Jumlah Data

Metode Parametrik	Metode Non-Parametrik
Asumsikan data ikuti model	Tidak asumsi model tertentu
Simpan parameter, buang data asli	Gunakan pendekatan statistik/data
Contoh: regresi, log-linear	Contoh: histogram, clustering, sampling

- **Parametrik** → memadatkan data dengan model matematis, hanya parameter yang disimpan.
- **Non-Parametrik** → tidak pakai asumsi model, gunakan teknik statistik seperti histogram, clustering, atau sampling.

Parametric Data Reduction: Regression and Log-Linear Models

Regresi Linear
- Data dimodelkan agar sesuai dengan garis luru
- Sering menggunakan metode kuadrat terkecil (least-square) untuk menyesuaikan garis.

Regresi Berganda (Multiple Regression)
- Memungkinkan variabel respons YYY dimodelkan sebagai fungsi linear dari vektor fitur multidimensi.

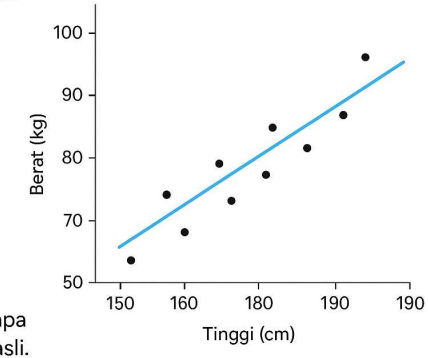
Model Log-Linear
- Mendekati distribusi probabilitas diskrit multidimensi.

Contoh Reduksi Data Parametrik: Regresi Sederhana

- Misal kita punya data tinggi dan berat badan 100 orang.
- Daripada menyimpan semua 100 pasang data, kita bisa buat model regresi linear:

$$Berat = 0{,}5 \times \text{Tinggi} - 20$$

- Model ini hanya menyimpan 2 parameter (0,5 dan –20).
- Dengan model ini, kita bisa memprediksi berat untuk tinggi berapa pun tanpa menyimpan semua data asli.



Intinya: Data "dipadatkan" *menjadi parameter* model sehingga lebih efisien.

DATA TRANSFORMATION AND DATA DISCRETIZATION

Data Transformation

Sebuah fungsi yang memetakan seluruh himpunan nilai dari atribut tertentu ke himpunan nilai pengganti yang baru
Setiap nilai lama dapat diidentifikasi dengan salah satu nilai baru.

Metode:

- **Penyamaan (Smoothing):** Menghapus noise dari data
- **Konstruksi atribut/fitur (Attribute/Feature Construction):** Membuat atribut baru dari atribut yang sudah ada
- **Agregasi (Aggregation):** Ringkasan data, pembuatan data cube
- **Normalisasi (Normalization):** Mengubah skala agar berada dalam rentang tertentu yang lebih kecil
  Normalisasi min-max
  Normalisasi z-score
  Normalisasi dengan decimal scaling
- **Diskretisasi (Discretization):** Pendakian hierarki konsep (concept hierarchy climbing)

Normalisasi

Min-max normalization: to [new_min$_A$, new_max$_A$]

$$v' = \frac{v - min_A}{max_A - min_A}(new_max_A - new_min_A) + new_min_A$$

$$\frac{73{,}600 - 12{,}000}{98{,}000 - 12{,}000}(1.0 - 0) + 0 = 0.716$$

Ex. Let income range \$12,000 to \$98,000 normalized to [0.0, 1.0]. Then \$73,000 is mapped to

Z-score normalization (μ: mean, σ: standard deviation):

$$v' = \frac{v - \mu_A}{\sigma_A}$$

$$\frac{73{,}600 - 54{,}000}{16{,}000} = 1.225$$

Ex. Let μ = 54,000, σ = 16,000. Then

Normalization by decimal scaling

$$v' = \frac{v}{10^j}$$

Where j is the smallest integer such that Max(|v'|) < 1

Diskretisasi

Proses mengubah data kontinu menjadi kategori atau interval diskrit agar lebih mudah dianalisis atau dimodelkan.

Tiga jenis atribut

Nominal — nilai dari himpunan yang tidak berurutan, misal: warna, profesi
Ordinal — nilai dari himpunan yang berurutan, misal: pangkat militer atau akademik
Numerik — bilangan nyata, misal: bilangan bulat atau bilangan real

Diskretisasi:

Membagi rentang atribut kontinu menjadi interval
Label interval kemudian dapat digunakan untuk menggantikan nilai data yang asli
Mengurangi ukuran data melalui diskretisasi

Pendekatan:

Supervised vs. Unsupervised
Split (top-down) vs. Merge (bottom-up)
Diskretisasi dapat dilakukan secara rekursif pada suatu atribut

Tujuan:

Mempersiapkan data untuk analisis lebih lanjut, misalnya: klasifikasi

Metode Diskretisasi Data

Typical methods: All the methods can be applied recursively

- Binning: Top-down split, unsupervised
- Histogram analysis: Top-down split, unsupervised
- Clustering analysis: Unsupervised, top-down split or bottom-up merge
- Decision-tree analysis: Supervised, top-down split
- Correlation (e.g., χ^2) analysis: unsupervised, bottom-up merge

Simple Discretization: Binning

Equal-width (distance) partitioning

- Divides the range into N intervals of equal size: uniform grid
- if A and B are the lowest and highest values of the attribute, the width of intervals will be: W = (B –A)/N.
- The most straightforward, but outliers may dominate presentation
- Skewed data is not handled well

Equal-depth (frequency) partitioning

- Divides the range into N intervals, each containing approximately same number of samples
- Good data scaling
- Managing categorical attributes can be tricky

Binning Methods for Data Smoothing

Sorted data for price (in dollars): 4, 8, 9, 15, 21, 21, 24, 25, 26, 28, 29, 34

Partition into equal-frequency (**equi-depth**) bins:

Bin 1: 4, 8, 9, 15
Bin 2: 21, 21, 24, 25
Bin 3: 26, 28, 29, 34

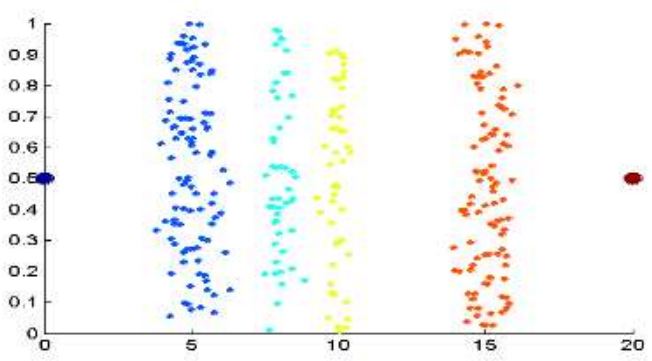
Smoothing by **bin means**:

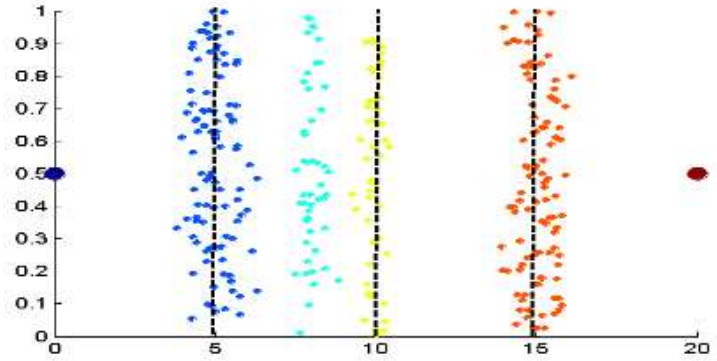
Bin 1: 9, 9, 9, 9
Bin 2: 23, 23, 23, 23
Bin 3: 29, 29, 29, 29

Smoothing by **bin boundaries**:

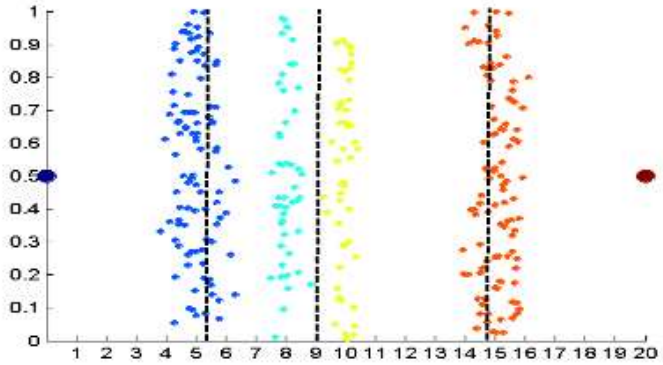
Bin 1: 4, 4, 4, 15
Bin 2: 21, 21, 25, 25
Bin 3: 26, 26, 26, 34

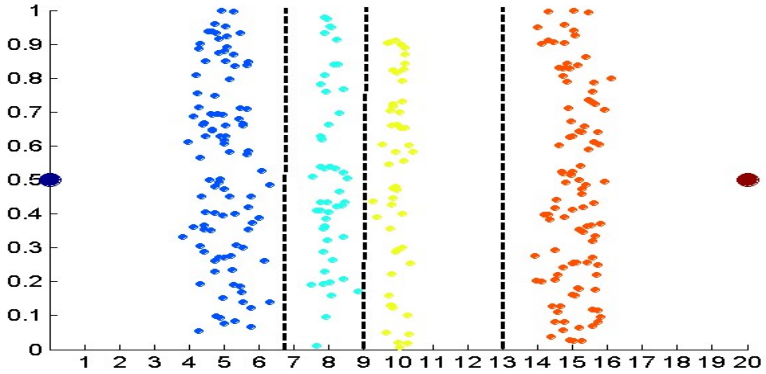
Discretization Without Using Class Labels (Binning vs. Clustering)





Data





Equal frequency (binning)

K-means clustering leads to better results

Classification (e.g., decision tree analysis)

- Supervised: Given class labels, e.g., cancerous vs. benign
- Using *entropy* to determine split point (discretization point)
- Top-down, recursive split

Correlation analysis (e.g., Chi-merge: χ^2-based discretization)

- Supervised: use class information
- Bottom-up merge: find the best neighboring intervals (those having similar distributions of classes, i.e., low χ^2 values) to merge
- Merge performed recursively, until a predefined stopping condition

DATA INTEGRATION

Integrasi Data

Integrasi Data:

Menggabungkan data dari berbagai sumber ke dalam satu penyimpanan yang koheren

Integrasi Skema (Schema Integration): Contoh: A.cust-id ≡ B.cust-#

Mengintegrasikan metadata dari berbagai sumber

Masalah Identifikasi Entitas (Entity Identification Problem):

Mengidentifikasi entitas dunia nyata dari beberapa sumber data, misal: Bill Clinton = William Clinton

Deteksi dan Penyelesaian Konflik Nilai Data:

Untuk entitas dunia nyata yang sama, nilai atribut dari sumber yang berbeda bisa berbeda

Kemungkinan penyebab: representasi berbeda, skala berbeda, misal: satuan metrik vs satuan Inggris

Konsep	Contoh / Visual	Penjelasan
Integrasi Data	MySQL (Toko A) + Excel (Toko B)	Menggabungkan berbagai sumber data menjadi satu penyimpanan terpadu
Integrasi Skema	cust_id ≡ customer_number	Menyamakan kolom atau metadata agar arti data konsisten
Identifikasi Entitas	"Bill Clinton" = "William Clinton"	Mengenali entitas yang sama meski penulisan berbeda
Resolusi Konflik Nilai	Tinggi: 180 cm ↔ 70.8 in	Menyelesaikan perbedaan nilai akibat representasi atau skala berbeda

Penanganan Redundansi dalam Integrasi Data

Data redundan sering muncul saat integrasi beberapa database

Identifikasi objek: Atribut atau objek yang sama mungkin memiliki nama berbeda di database yang berbeda.

Data turunan (Derivable data): Satu atribut bisa menjadi atribut “turunan” di tabel lain, misal: pendapatan tahunan.

Deteksi atribut redundan: Dapat dilakukan melalui analisis korelasi dan analisis kovarians.

Penanganan: Integrasi data dari berbagai sumber secara hati-hati dapat membantu mengurangi/menghindari redundansi dan inkonsistensi serta meningkatkan kecepatan dan kualitas proses data mining.

Referensi

1. Jiawei Han and Micheline Kamber, Data Mining: Concepts and Techniques Third Edition, *Elsevier*, 2012
2. Ian H. Witten, Frank Eibe, Mark A. Hall, Data mining: Practical Machine Learning Tools and Techniques 3rd Edition, *Elsevier*, 2011
3. Markus Hofmann and Ralf Klinkenberg, RapidMiner: Data Mining Use Cases and Business Analytics Applications, *CRC Press Taylor & Francis Group*, 2014
4. Daniel T. Larose, Discovering Knowledge in Data: an Introduction to Data Mining, *John Wiley & Sons*, 2005
5. Ethem Alpaydin, Introduction to Machine Learning, 3rd ed., *MIT Press*, 2014
6. Materi "Thematic Academy: AI dan DS untuk Dosen dan Instruktur", 2021.
7. Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow - Geron Aurelien, 2019 https://www.ibm.com/think/topics/artificial-intelligence - Cole Stryker, Eda Kavlakoglu, 2024
8. Lifecycle of machine learning models – Oracle https://www.ibm.com/think/insights/ai-adoption-challenges
9. Cole Stryker, 2025 https://provost.wsu.edu/challenges-of-ai/ - Washington State University


thank you
danke
謝謝
ngiyabonga
teşekkür ederim
gracias
спасибо
bedankt
dziękuję
obrigado
merci
go raibh maith agat
sukriya
kop khun krap
terima kasih
grazie
arigatō
dakujem
takk
tapadh leat
mochchakkeram
dank je
hvala
mauruuru
sagolun
tänk
merci
рахмат
Баярлалаа
ευχαριστώ
감사합니다
мерси