PEMBELAJARAN MESIN

Regresi

Team Teaching Machine Learning

Outlines

- Simple Linear Regression
- Multiple Linear Regression
- Regresi Non-Linier dan SVR

- Variable yang digunakan pada linear regression adalah satu atau lebih variable independent/penjelas/bebas (X) dan variable dependent/respon/tidak bebas (Y)

Macam-Macam Model Regresi:

- **Regresi Linier Sederhana**: Digunakan ketika hanya ada satu variabel independen.
- **Regresi Linier Berganda**: Digunakan ketika ada beberapa variabel independen.
- **Regresi Non-Linier**: Digunakan ketika hubungan antara variabel independen dan dependen tidak linier.

Penerapan Regresi dalam Berbagai Bidang

- Ekonomi : Untuk memahami faktor-faktor yang memengaruhi penjualan atau harga.
- Kesehatan : Untuk memprediksi parameter medis berdasarkan faktor-faktor tertentu.
- Sains Sosial : Untuk menganalisis perilaku manusia.
- Ilmu Lingkungan: Untuk memahami dampak variabel lingkungan.

Perbedaan Regresi & Klasifikasi

- **Regresi:**
- Variabel Dependennya adalah Kuantitatif: Regresi digunakan ketika variabel dependen adalah kuantitatif atau berkelanjutan. Ini berarti kita ingin memprediksi nilai yang dapat diukur secara numerik.
- Contoh: Memprediksi harga rumah, gaji seseorang, suhu, atau nilai ujian adalah contoh dari masalah regresi. Dalam hal ini, hasil yang ingin kita prediksi adalah angka.

Perbedaan Regresi & Klasifikasi

Klasifikasi:

- Variabel Dependennya adalah Kualitatif: Klasifikasi digunakan ketika variabel dependen adalah kualitatif atau kategorikal. Ini berarti kita ingin mengelompokkan atau mengklasifikasikan data ke dalam kategori tertentu.
- Contoh: Mengklasifikasikan email sebagai spam atau bukan spam, mengidentifikasi jenis bunga berdasarkan fitur-fiturnya, atau mengklasifikasikan gambar sebagai kucing atau anjing. Dalam hal ini, hasil yang ingin kita prediksi adalah kategori atau label.

Perbedaan Regresi & Klasifikasi

- Perbedaan dalam algoritma dan metode yang digunakan dalam regresi dan klasifikasi. Misalnya, dalam regresi, kita menggunakan algoritma seperti Regresi Linier untuk memprediksi nilai numerik, sementara dalam klasifikasi, kita menggunakan algoritma seperti Naive Bayes, Decision Trees, atau Support Vector Machines untuk mengklasifikasikan data ke dalam kategori.
- Jadi, inti perbedaan antara regresi dan klasifikasi adalah jenis output yang ingin diprediksi: nilai kuantitatif untuk regresi dan label kualitatif atau kategori untuk klasifikasi.

Simple Linier Regression

- Simple Linear Regression (Regresi Linier Sederhana) adalah suatu teknik analisis statistik yang digunakan untuk memahami dan memodelkan hubungan linier antara dua variabel: variabel independen (X) dan variabel dependen (Y).

Simple Linier Regression

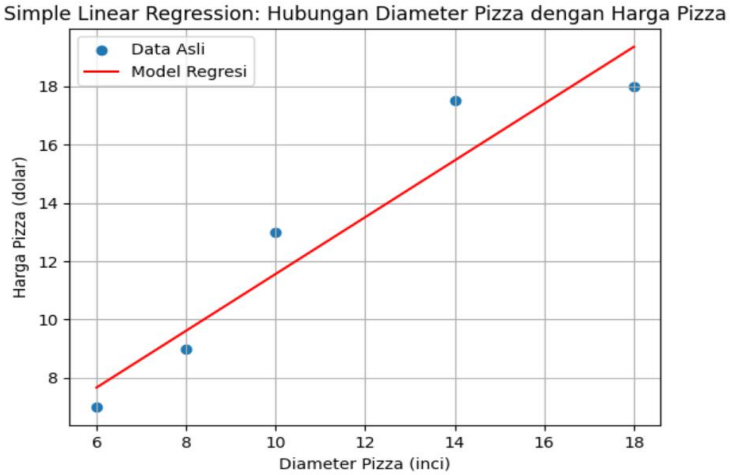
- Hubungan linear dalam bentuk persamaan garis lurus antara dua variable ini dapat dirumuskan sebagai berikut ini:
- $Y=\beta_0+\beta_1 X$
    - Y adalah variabel dependen yang ingin diprediksi atau dimengerti.
    - X adalah variabel independen yang digunakan untuk melakukan prediksi atau menjelaskan variasi dalam Y.
    - β_0 adalah intercept (konstanta), yaitu nilai Y ketika X sama dengan 0.
    - β_1 adalah koefisien regresi, yang mengukur sejauh mana perubahan dalam X memengaruhi perubahan dalam Y. Ini adalah kemiringan (slope) dari garis regresi.

Contoh : Hubungan Diameter Pizza dengan Harga Pizza

- Misalkan kita ingin memahami hubungan antara diameter pizza (dalam inci) dan harga pizza (dalam dolar).
- Kita mengumpulkan data dari beberapa toko pizza dan memutuskan untuk menggunakan Simple Linear Regression untuk memodelkan hubungan ini. Berikut adalah data yang kita miliki:

Contoh : Hubungan Diameter Pizza dengan Harga Pizza

Diameter Pizza (X) (inci)	Harga Pizza (Y) (dolar)
6	7
8	9
10	13
14	17.5
18	18



Multiple Linear Regression

- **Multiple linear Regression** merupakan turunan dari simple linear regression, multiple linear juga menghasilkan prediksi dalam bentuk angka kontinyu, perbedaan antara simple dan multiple adalah pada data variable independent/penjelas/bebas (X) dimana dalam multiple linear terdapat beberapa fitur / variable independent.

Contoh Penerapan: Hubungan Diameter Pizza dengan Harga Pizza

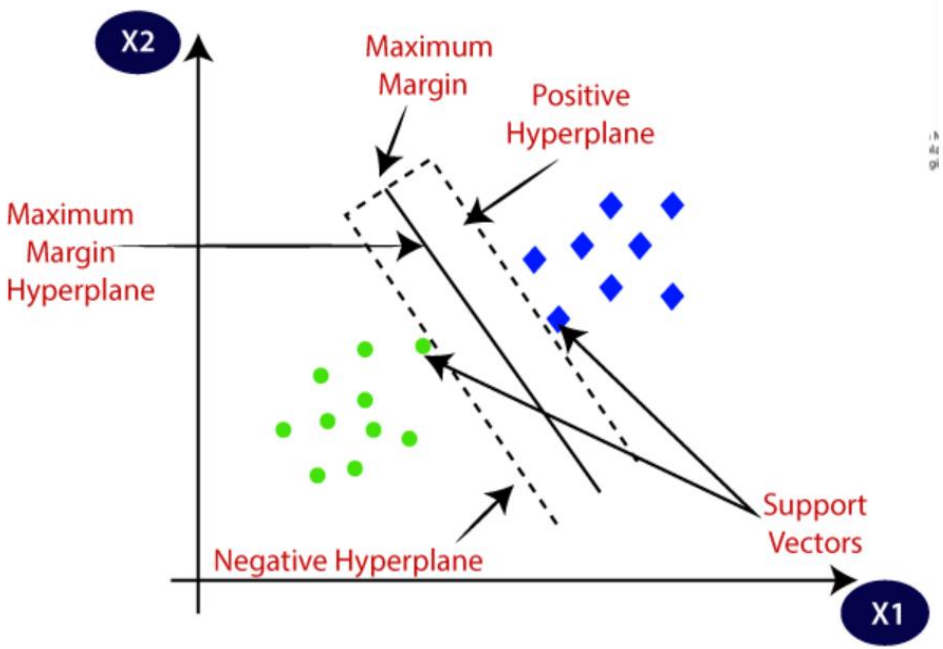
- Hubungan linear antara variable independent dan variable dependent pada multiple regression :
- $y=\alpha+\beta_{1x1}+\beta_{2x2}+\cdots+\beta nxn$
- $Y=\beta X$
  - y adalah vektor kolom nilai variabel respon/dependent.
  - α adalah nilai intercept
  - β adalah vektor kemiringan (slope)
  - X adalah matriks berdimensi m kali n dari nilai variabel independent pada data training
  - m adalah jumlah data training.
  - n adalah jumlah fitur.

Support Vector

- Dalam statistik dan analisis data, "Support Vector" merujuk kepada konsep yang umumnya digunakan dalam berbagai konteks, termasuk regresi, pemisahan data, dan pemodelan statistik.
- Support Vector adalah titik-titik data yang memiliki peran penting dalam analisis atau pemodelan statistik. Mereka adalah titik-titik yang secara signifikan memengaruhi pemahaman kita tentang distribusi data, tren, atau pemisahan kelas.

Support Vector

- Support Vector adalah titik-titik data yang memiliki peran penting dalam analisis atau pemodelan statistik. Mereka adalah titik-titik yang secara signifikan memengaruhi pemahaman kita tentang distribusi data, tren, atau pemisahan kelas.

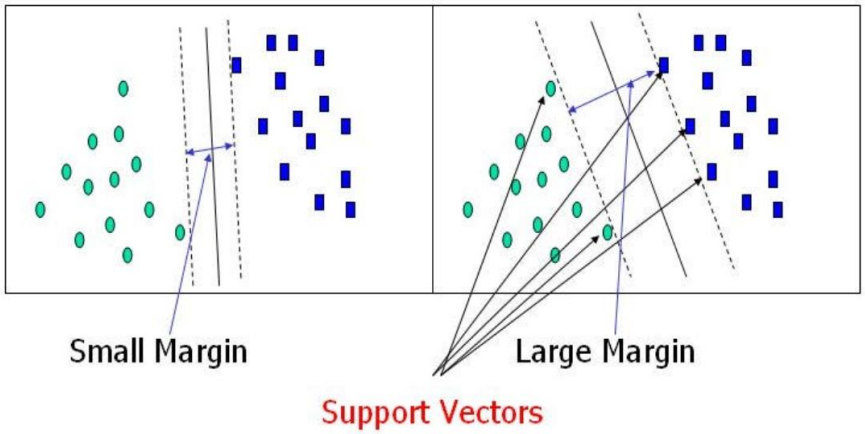


Max Margin

- Margin adalah jarak antara support vector dari masing-masing kelas di sekitar hyperplane. Pada gambar dibawah, margin diilustrasikan dengan jarak antara 2 garis putus.
- Margin terbesar (max margin) dapat ditemukan dengan memaksimalkan nilai jarak antara hyperplane dan titik terdekatnya.
- Dapat dilihat pada gambar 3.6 bagian kanan memiliki margin lebih besar daripada gambar bagian kiri. Secara intuitif, margin yang lebih besar akan menghasilkan performa klasifikasi yang lebih baik.

Max Margin

- Dapat dilihat pada gambar berikut, bagian kanan memiliki margin lebih besar daripada gambar bagian kiri.
- Secara intuitif, margin yang lebih besar akan menghasilkan performa klasifikasi yang lebih baik.

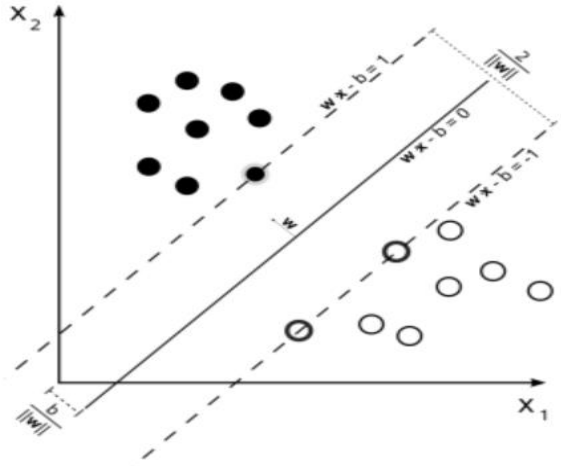


Support Vector Regression (SVR)

- Support Vector Regression (SVR) adalah salah satu teknik dalam pembelajaran mesin yang digunakan untuk melakukan regresi, yaitu memprediksi nilai numerik atau kontinu berdasarkan data pelatihan.
- SVR adalah varian dari Support Vector Machines (SVM) yang awalnya dikembangkan untuk klasifikasi, tetapi kemudian diperluas ke masalah regresi.

Support Vector Regression (SVR)

- Untuk lebih mudahnya mari kita awali dari penjelasan SVM melalui ilustrasi gambar di bawah ini:



Support Vector Regression (SVR)

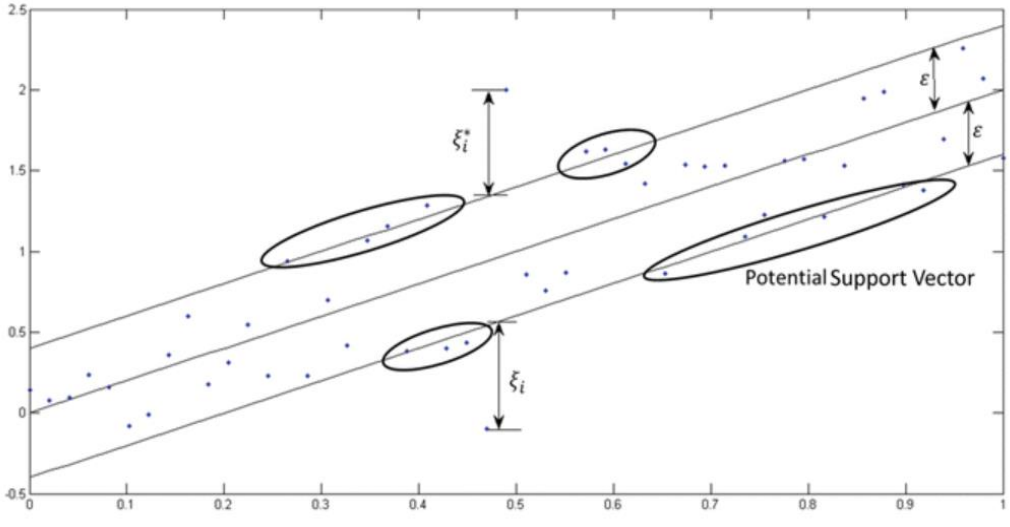
- Garis Paling Atas (Garis Putus-Putus): Garis ini adalah garis batas positif (+), yang berarti garis ini melewati atau melalui titik-titik data yang termasuk dalam kluster positif.
- Titik-titik data ini sering disebut sebagai "support vectors" dan menjadi titik-titik terluar dari kluster positif.
- Garis Tengah: Garis ini disebut sebagai "hyperplane" atau "separating plane/line." Garis ini bertindak sebagai pemisah antara dua zona (kluster positif dan negatif).
- Garis Paling Bawah (Garis Putus-Putus): Garis ini adalah garis batas negatif (-), yang artinya garis ini melewati satu titik data yang termasuk dalam kluster negatif.

Support Vector Regression (SVR)

- Garis Paling Atas (Garis Putus-Putus): Garis ini adalah garis batas positif (+), yang berarti garis ini melewati atau melalui titik-titik data yang termasuk dalam kluster positif.
- Titik-titik data ini sering disebut sebagai "support vectors" dan menjadi titik-titik terluar dari kluster positif.
- Garis Tengah: Garis ini disebut sebagai "hyperplane" atau "separating plane/line." Garis ini bertindak sebagai pemisah antara dua zona (kluster positif dan negatif).
- Garis Paling Bawah (Garis Putus-Putus): Garis ini adalah garis batas negatif (-), yang artinya garis ini melewati satu titik data yang termasuk dalam kluster negatif.

Support Vector Regression (SVR)

- Dapat disimpulkan bahwa SVM bertujuan memisahkan dataset menjadi dua zona, sementara SVR bertujuan memasukkan semua dataset ke dalam satu zona sambil meminimalkan nilai epsilon (ε), dengan kata lain SVM membagi menjadi dua zona sedangkan SVR memasukkan semuanya menjadi satu zona.



Evaluasi Model SVR:

- Mean Absolute Error (MAE): MAE mengukur rata-rata dari selisih absolut antara nilai aktual dan nilai prediksi. Semakin rendah nilai MAE, semakin baik model SVR Anda.
- Mean Squared Error (MSE): MSE mengukur rata-rata dari kuadrat selisih antara nilai aktual dan nilai prediksi. MSE memberikan "penalty" yang lebih besar pada error yang besar.
- Root Mean Squared Error (RMSE): RMSE adalah akar kuadrat dari MSE dan memberikan hasil dalam satuan yang sama dengan variabel target. Semakin kecil RMSE, semakin baik model Anda.
- R-squared mengukur seberapa baik variabilitas dalam data target dapat dijelaskan oleh model. Rentang skor R-squared antara 0 hingga 1, dan semakin mendekati 1, semakin baik model Anda dalam menjelaskan variasi data.

Let’s get your hands dirty!

Regression Practice!