PEMBELAJARAN MESIN

K-Nearest Neighbor (KNN)

Team Teaching Machine Learning

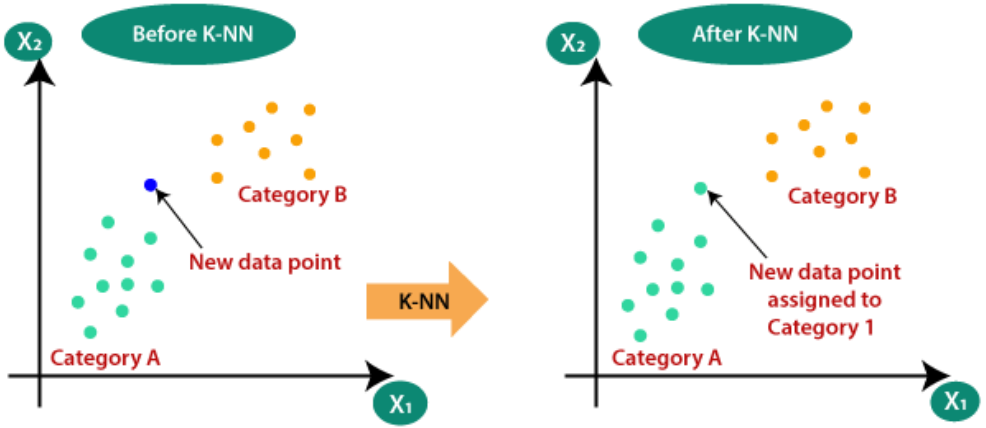
Outlines

- Pengertian dan Konsep Dasar KNN
- Langkah-langkah Algoritma KNN
- Pemilihan Nilai K
- Contoh Kasus dan Ilustrasi
- Kelebihan & Kekurangan

Pengertian dan konsep Dasar KNN

K-Nearest Neighbors (KNN) adalah algoritma supervised learning yang digunakan untuk klasifikasi dan regresi.

Data baru diklasifikasikan berdasarkan kedekatan jarak dengan data lain yang sudah diketahui kelasnya.



Langkah-langkah Algoritma KNN

- Mengambil dataset dengan label kelas.
- Menentukan nilai K.
- Menghitung jarak ke semua data latih.
- Mengurutkan jarak dari kecil ke besar.
- Mengambil K tetangga terdekat.
- Memprediksi berdasarkan mayoritas kelas.

Pemilihan Nilai K

- K kecil → sensitif terhadap noise (overfitting).
- K besar → lebih stabil tapi bisa underfitting.
- Gunakan cross-validation untuk menentukan K terbaik.

Langkah-langkah Algoritma KNN

- Mengambil dataset dengan label kelas.
- Menentukan nilai K.
- Menghitung jarak ke semua data latih.
- Mengurutkan jarak dari kecil ke besar.
- Mengambil K tetangga terdekat.
- Memprediksi berdasarkan mayoritas kelas.

Langkah-langkah Algoritma KNN

- Untuk mencari dekat atau jauhnya jarak antar titik pada kelas k biasanya dihitung
- menggunakan jarak Euclidean. Jarak Euclidean adalah formula untuk mencari jarak antara 2 titik dalam ruang dua dimensi.
- Berikut rumus untuk menghitung jarak Euclidean:

$$= \sqrt{(q_1 - p_1)^2 + (q_2 - p_2)^2 + \cdots + (q_n - p_n)^2}$$

$$= \sqrt{\sum_{i=1}^{n} (q_i - p_i)^2}.$$

Contoh Kasus dan ilustrasi

Misalnya ada sebuah rumah yang **berada tepat di tengah perbatasan** antara Kota Malang dan Kabupaten Malang, sehingga pemerintah kesulitan untuk menentukan **apakah rumah tersebut termasuk kedalam wilayah Kota Malang atau Kabupaten Malang**.

Untuk menentukannya bisa dengan menggunakan **Algoritma KNN**, yaitu dengan melibatkan jarak antara rumah tersebut dengan rumah-rumah yang ada disekitarnya (tetangganya).



Langkah-langkah Algoritma KNN

- **Pertama,** harus menentukan jumlah tetangga yg akan kita perhitungkan (k), misalnya menentukan 3 tetangga terdekat (k = 3).
- **Kedua,** hitung jarak setiap tetangga terhadap rumah tersebut, lalu urutkan hasilnya berdasarkan jarak, mulai dari yang terkecil ke yang terbesar.
- **Ketiga,** ambil 3 (k) tetangga yg paling dekat, lalu kita lihat masing-masing dari tetangga tersebut apakah termasuk kedalam wilayah Kota atau Kabupaten.

Ada 2 kemungkinan:

1. Bila dari 3 tetangga tersebut terdapat ada 2 rumah yg termasuk kedalam wilayah Kota Malang, maka rumah tersebut termasuk kedalam wilayah Kota Malang.
2. Sebaliknya, bila dari 3 tetangga tersebut terdapat 2 rumah yg termasuk kedalam wilayah Kabupaten Malang, maka rumah tersebut termasuk kedalam wilayah Kabupaten Malang).

Pembahasan lebih detail

Pada kasus tersebut, dengan menghitung jarak suatu rumah terhadap tetangga-tetangganya, itu berarti harus mengetahui posisi dari setiap rumah.

Dengan menggunakan *latitude* dan *longitude* (atau garis lintang dan garis bujur) sebagai posisi.

Untuk mempermudah pemahaman, akan mencoba menggunakan data yang nilainya sederhana. Data yang akan digunakan adalah sebagai berikut:

Rumah	Lat	Long	Lokasi
A	11	26	Kota
B	15	29	Kota
C	19	28	Kota
D	18	30	Kota
E	16	26	Kota
F	23	25	Kabupaten
G	25	22	Kabupaten
H	21	24	Kabupaten
I	23	25	Kabupaten
J	29	24	Kabupaten
X	19	25	?

Pembahasan lebih detail

Dari *data* diatas, didapatkan beberapa informasi, diantaranya:

1. Independent Variables, yaitu variable yang nilainya **tidak dipengaruhi** oleh variable lain. Pada contoh *data* diatas, yang termasuk *independent variable* adalah ***Lat***, dan ***Long***.

2. Dependent Variables, yaitu *variable* yang nilainya **dipengaruhi** oleh *variable* lain. Pada contoh *data* diatas, yang termasuk *dependent variable* adalah **Lokasi**.

3. Rumah A-E adalah rumah yang masuk ke dalam wilayah **Kota**.

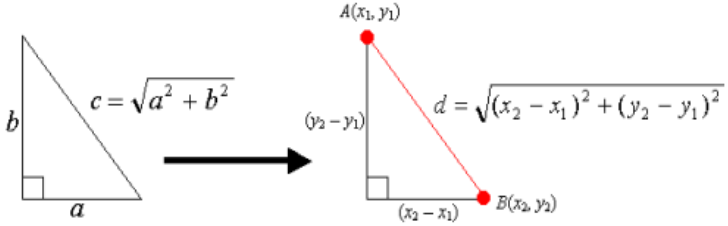
4. Rumah F-J adalah rumah yang masuk ke dalam wilayah **Kabupaten**.

5. Rumah X adalah rumah yang akan kita prediksi menggunakan algoritma kNN apakah termasuk ke dalam wilayah Kota atau Kabupaten.

Rumah	Lat	Long	Lokasi
A	11	26	Kota
B	15	29	Kota
C	19	28	Kota
D	18	30	Kota
E	16	26	Kota
F	23	25	Kabupaten
G	25	22	Kabupaten
H	21	24	Kabupaten
I	23	25	Kabupaten
J	29	24	Kabupaten
X	19	25	?

Pembahasan lebih detail

Selanjutnya kita hitung jarak antara rumah X terhadap rumah A-G dengan menggunakan rumus:



Diketahui, dimana **x** adalah ***Lat***, **y** adalah ***Long***, sedangkan **(x1, y1)** adalah *lat* dan *long* dari **rumah X**, dan **(x2, y2)** adalah *lat* dan *long* dari **masing-masing tetangganya**.

Setelah dihitung, selanjutnya adalah **urutkan jarak tersebut dari yang paling kecil ke yang paling besar**, hasilnya adalah sebagai berikut:

Rumah	Lat	Long	Jarak Terhadap Rumah X
H	21	24	2.24
C	19	28	3.00
E	16	26	3.16
F	23	25	4.00
I	23	25	4.00
D	18	30	5.10
B	15	29	5.66
G	25	22	6.71
A	11	26	8.06
J	29	24	10.05

Pembahasan lebih detail

Dapat dilihat dari hasil perhitungan tersebut, bahwa ternyata 3 tetangga terdekat dari rumah X adalah:

Rumah H (Kabupaten) yang memiliki jarak **2.24**,
Rumah C (Kota) yang memiliki jarak **3**, dan
Rumah E (Kota) yang memiliki jarak **3.16**.

Dari ke-3 tetangga terdekat, terdapat **2 rumah** yang termasuk kedalam wilayah **Kota** dan **1 rumah** yang masuk ke dalam wilayah **Kabupaten**.

Sehingga dapat disimpulkan, bahwa **Rumah X adalah rumah yang termasuk kedalam wilayah Kota Malang**

Rumah	Lat	Long	Jarak Terhadap Rumah X
H	21	24	2.24
C	19	28	3.00
E	16	26	3.16
F	23	25	4.00
I	23	25	4.00
D	18	30	5.10
B	15	29	5.66
G	25	22	6.71
A	11	26	8.06
J	29	24	10.05

Kelamahan dan kelebihan KNN

Kelebihan KNN:

1. Sederhana dan mudah dipahami.
2. Tidak memerlukan asumsi yang kuat tentang data.
3. Dapat digunakan untuk klasifikasi dan regresi.
4. Dapat digunakan untuk data numerik dan kategorikal.

Kelemahan KNN:

1. Sangat sensitif terhadap skala data dan fitur yang tidak relevan.
2. Memerlukan penyimpanan data training secara lengkap.
3. Memerlukan waktu komputasi yang signifikan saat jumlah data besar.
4. Memerlukan pemilihan parameter K yang tepat.

Let’s get your hands dirty!

Regression Practice!