Pembelajaran Mesin

Klasifikasi – Support Vector Machine (SVM)

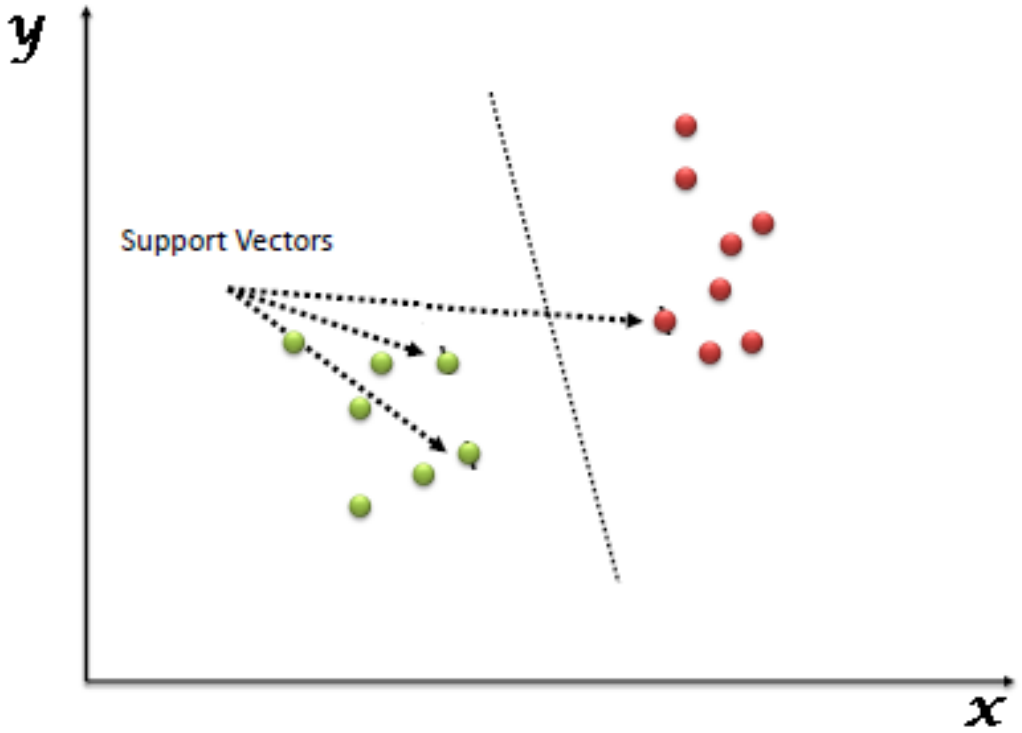
Outlines

- Apa itu Support Vector Machine?
- Kernel dan Kernel Tricks
- Maximum Margin dan Support Vector

Apa itu Support Vector Machine (SVM)?

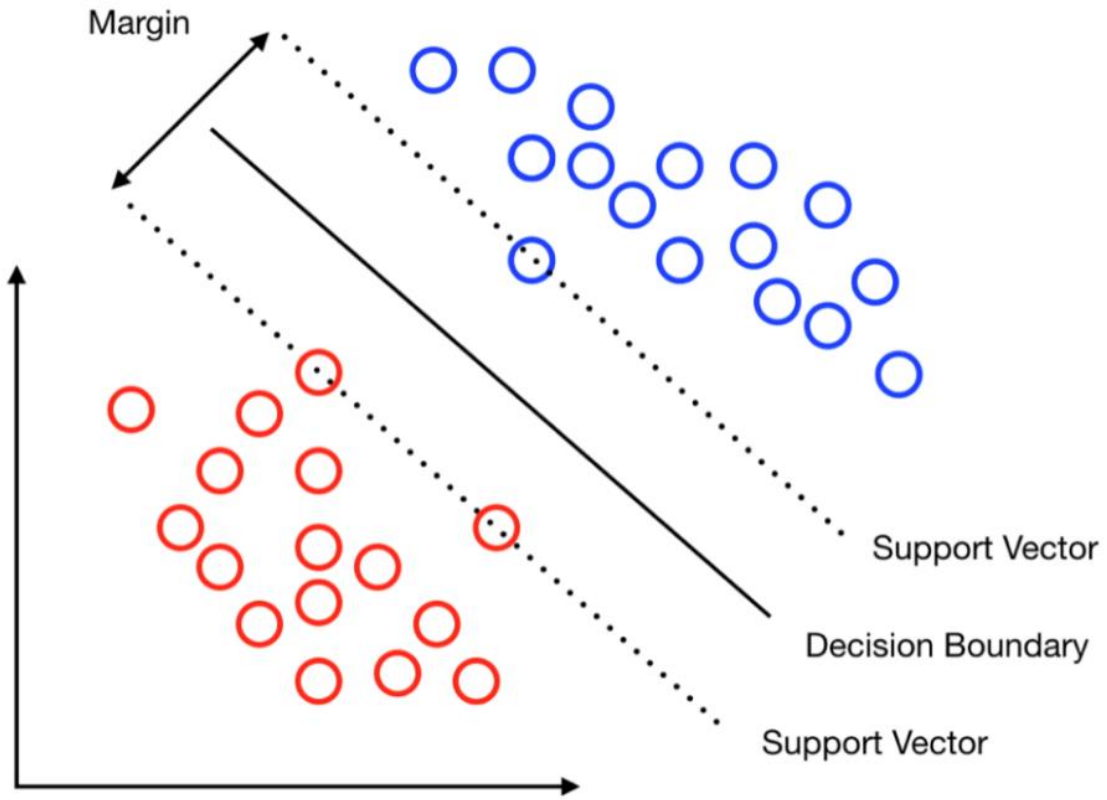
SVM #1

- Sebuah algoritma pembelajaran mesin terbimbing (supervised).
- Dapat digunakan untuk **klasifikasi** maupun **regresi**, namun paling sering digunakan untuk klasifikasi.
- Berusaha mencari garis yang "paling baik" dalam memisahkan dua kelas titik data.
- "Paling baik" berarti garis yang menghasilkan **margin terbesar** antara kedua kelas tersebut.



SVM #2

- Dalam algoritma SVM, setiap data diplot sebagai sebuah titik di **ruang berdimensi-n** (di mana n adalah jumlah fitur yang dimiliki), dengan nilai setiap fitur merepresentasikan nilai dari suatu koordinat tertentu.
- Klasifikasi dilakukan dengan mencari **hyperplane** yang memisahkan dua kelas tersebut dengan sangat baik.



Mengapa menggunakan SVM?

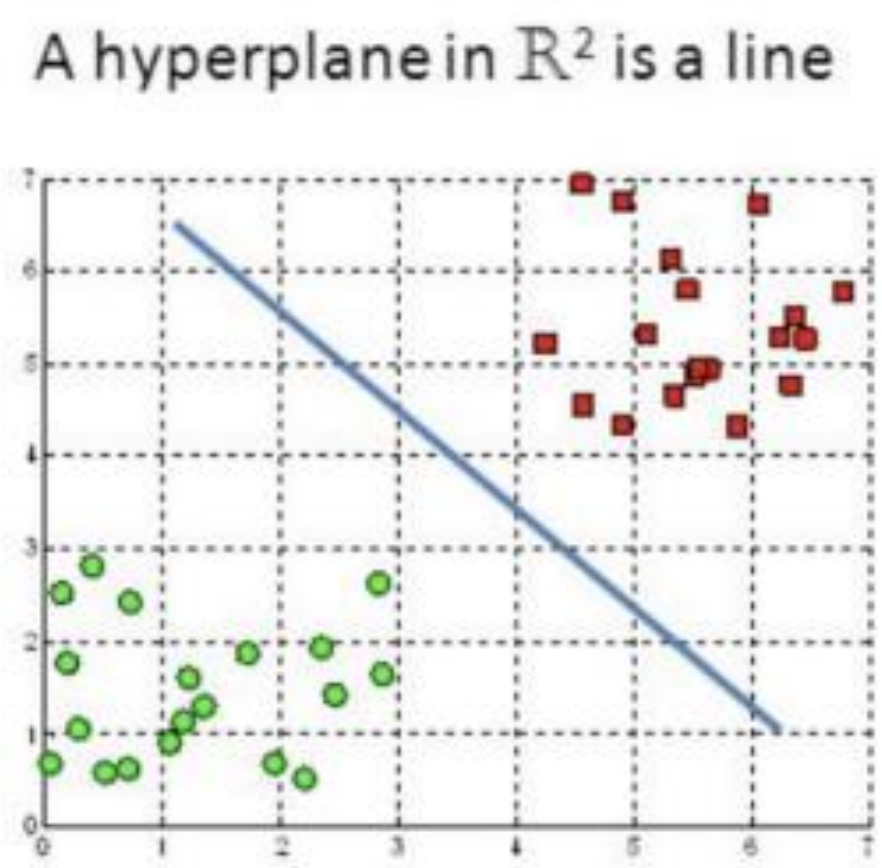
Pemodelan hubungan linier antara variabel respon dan fitur pada ruang fitur berdimensi tinggi memiliki dua masalah:

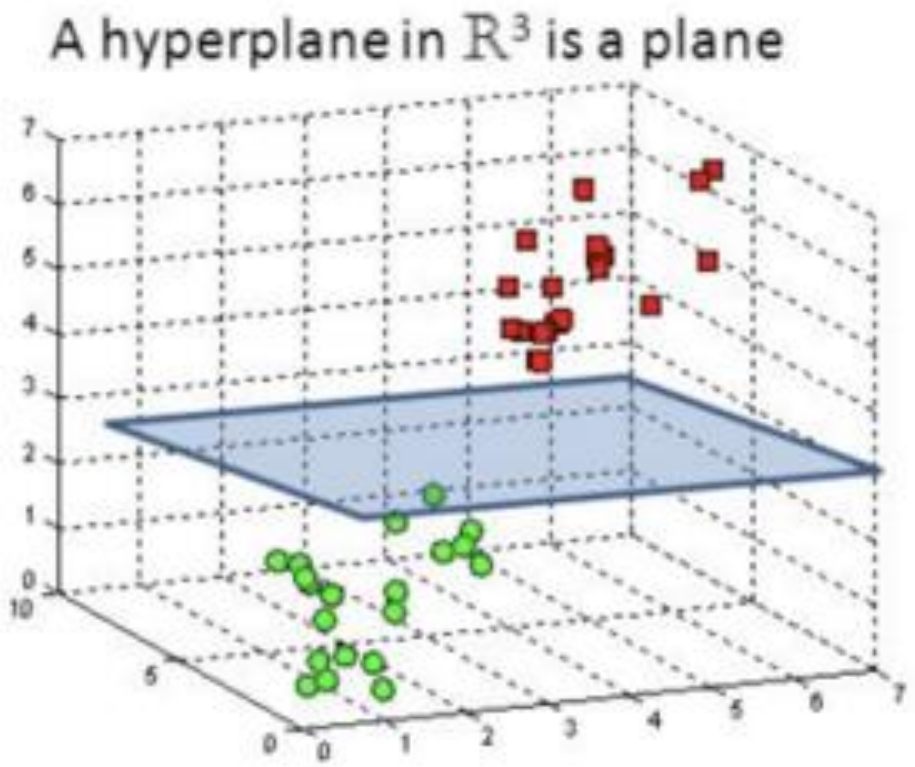
1. **Masalah komputasi**, yaitu perhitungan fitur yang dipetakan dan bekerja dengan vektor berukuran besar memerlukan daya komputasi yang lebih tinggi.
2. **Generalisasi**, yaitu peningkatan dimensi pada representasi fitur memperparah masalah *curse of dimensionality*, karena pembelajaran dari representasi fitur berdimensi tinggi memerlukan data latih yang jauh lebih banyak untuk menghindari *overfitting*.

Hyperplanes

- Dapat dianggap sebagai **batas keputusan (decision boundaries)** yang mengklasifikasikan titik-titik data ke dalam kelas masing-masing di ruang multi-dimensi.
- Titik data yang berada di salah satu sisi **hyperplane** dapat dianggap termasuk ke dalam kelas yang berbeda.
- **Generalisasi dari sebuah bidang:**
  - Dalam dua dimensi, disebut **garis**.
  - Dalam tiga dimensi, disebut **bidang**.
  - Dalam dimensi yang lebih tinggi, disebut **hyperplane**.

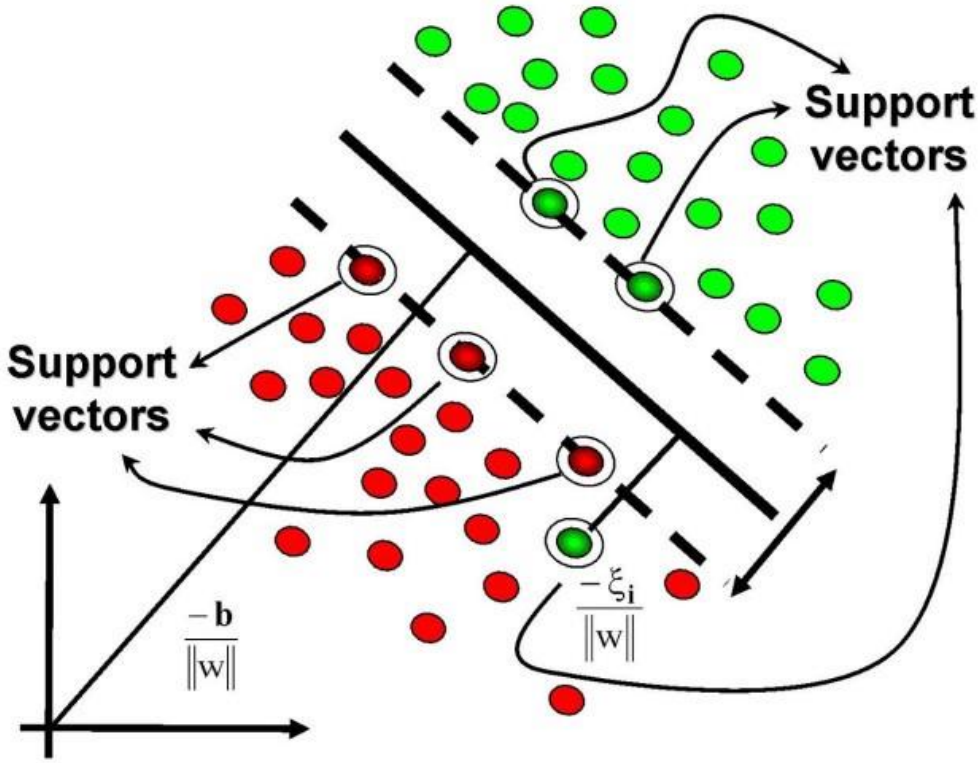
Ilustrasi Hyperplane





Support Vectors

- Titik-titik yang **terletak pada atau berada di dalam margin**.
- Digunakan untuk merumuskan pencarian "**margin hyperplane**", yaitu garis yang paling baik memisahkan dua kelas.
- Disebut juga sebagai **bentuk ganda (dual form)**.
- Dapat digunakan untuk menerapkan **trik kernel (kernel trick)** guna secara efektif mengubah **SVM menjadi pengklasifikasi non-linear**.



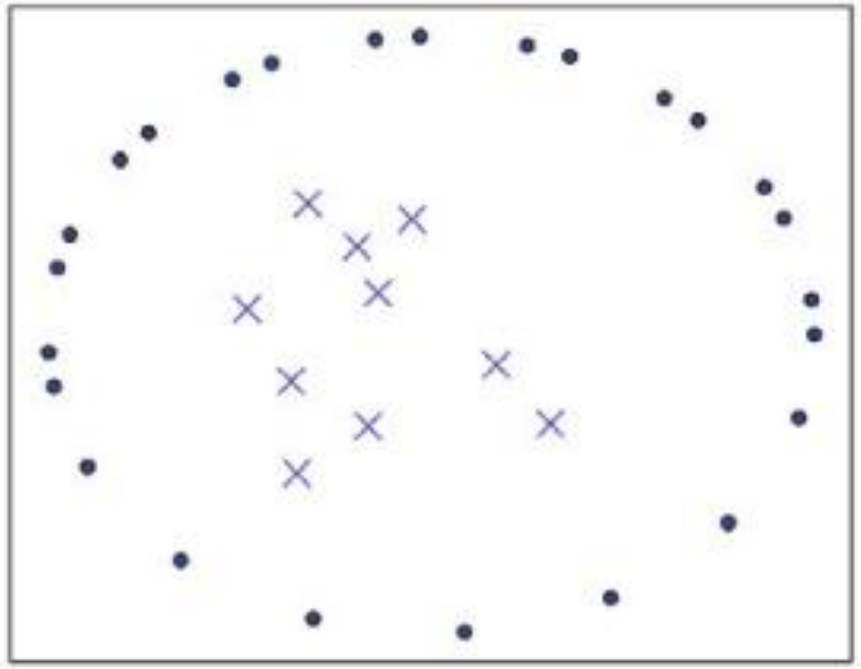
Komputasi Dual Form

$f(x) = \langle w, x \rangle + b = \sum \alpha_i y_i \langle x_i, x \rangle + b$, where $\langle w, x \rangle = wTx = w^T x$

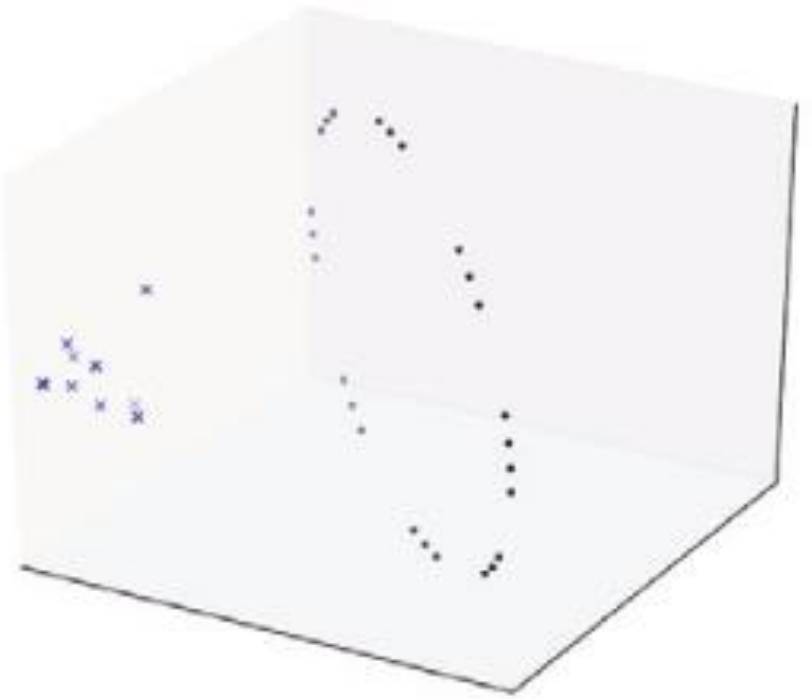
- α_{n} adalah parameter Lagrange, dan b adalah parameter pengklasifikasi.
- **Bentuk ganda (dual form)** menghitung **perkalian dalam (inner product)** antara vektor fitur dari data latih dan data uji.
- Sifat ini digunakan untuk menangani **kelas yang tidak dapat dipisahkan secara linear (linearly inseparable classes)**.
- Definisi pemetaan fitur ke ruang berdimensi lebih tinggi dapat diformalkan sebagai berikut.

$$x \rightarrow \phi(x)$$
$$\phi: R^d \rightarrow R^D$$

Transformasi (Mapping) ke Dimensi Lebih Tinggi #1



Linearly inseparable dataset
in **lower** dimensional space



Linearly separable dataset in
higher dimensional space

Transformasi (Mapping) ke Dimensi Lebih Tinggi #2

- **Lower** dimensional space mapping

$$f(x) = \sum \alpha_i y_i \langle x_i, x \rangle + b$$

- **Higher** dimensional space mapping

$$f(x) = \sum \alpha_i y_i \langle \phi(x_i), \phi(x) \rangle + b$$

  - Mapping feature vectors ke dimensi yang lebih tinggi, feature vectors hanya muncul sebagai nilai **dot product**.
  - Dot product merupakan nilai **scalar**.

Kernel dan Kernel Trick

Kernel

- Kernel adalah **sebuah fungsi** yang berdasarkan vektor fitur aslinya menghasilkan nilai yang sama dengan **hasil kali titik (dot product)** dari vektor fitur yang telah dipetakan.
- Kernel **tidak secara eksplisit** memetakan vektor fitur ke ruang berdimensi lebih tinggi atau menghitung hasil kali titik dari vektor yang telah dipetakan.
- Kernel menghasilkan nilai yang sama melalui **serangkaian operasi berbeda** yang sering kali dapat dihitung dengan lebih efisien.

$$K(x, z) = \langle \phi(x), \phi(z) \rangle$$

Komputasi Kernel

- Diberikan dua feature vector, $x = (x_1, x_2)$ and $z = (z_1, z_2)$
- Mapping vector ke dimensi yang lebih tinggi dimana transformasi $\phi(x) = x^2$, sehingga **dot product** nya:

$$\langle \phi(x), \phi(z) \rangle = \left\langle \left(x_1^2, x_2^2\sqrt{2x_1x_2}\right), \left(z_1^2, z_2^2\sqrt{2z_1z_2}\right) \right\rangle$$

- **Kernel** :

$$K(x, z) = (x, z)^2 = (x_1z_1 + x_2z_2)^2$$
$$= x_1^2z_1^2 + 2x_1z_1x_2z_2 + x_2^2z_2^2$$

Jenis-jenis Kernel

- Polynomial

$$K(x, x') = (\gamma\langle x - x'\rangle + r)^k$$

- Sigmoid

$$K(x, x') = tanh(\gamma\langle x - x'\rangle + r)$$

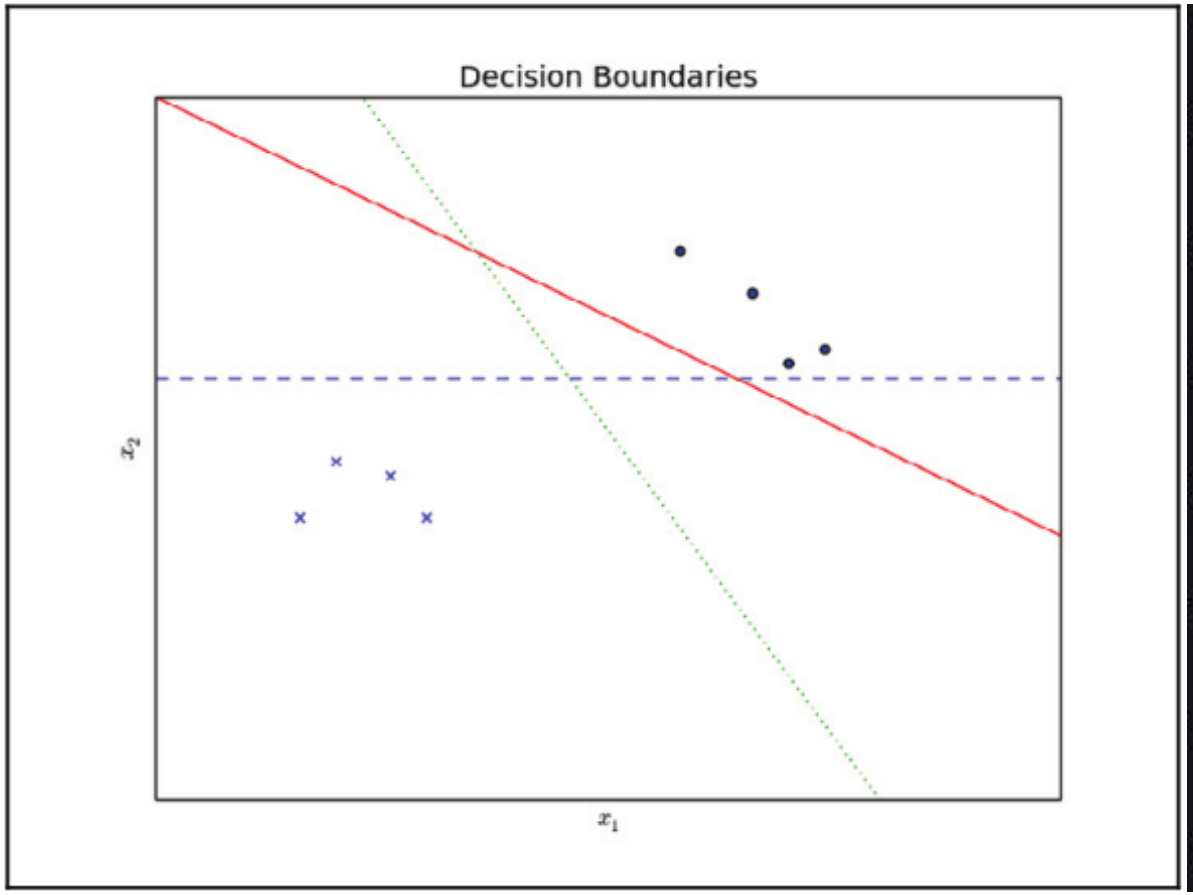
- Gaussian atau Radial Basis Function (RBF)

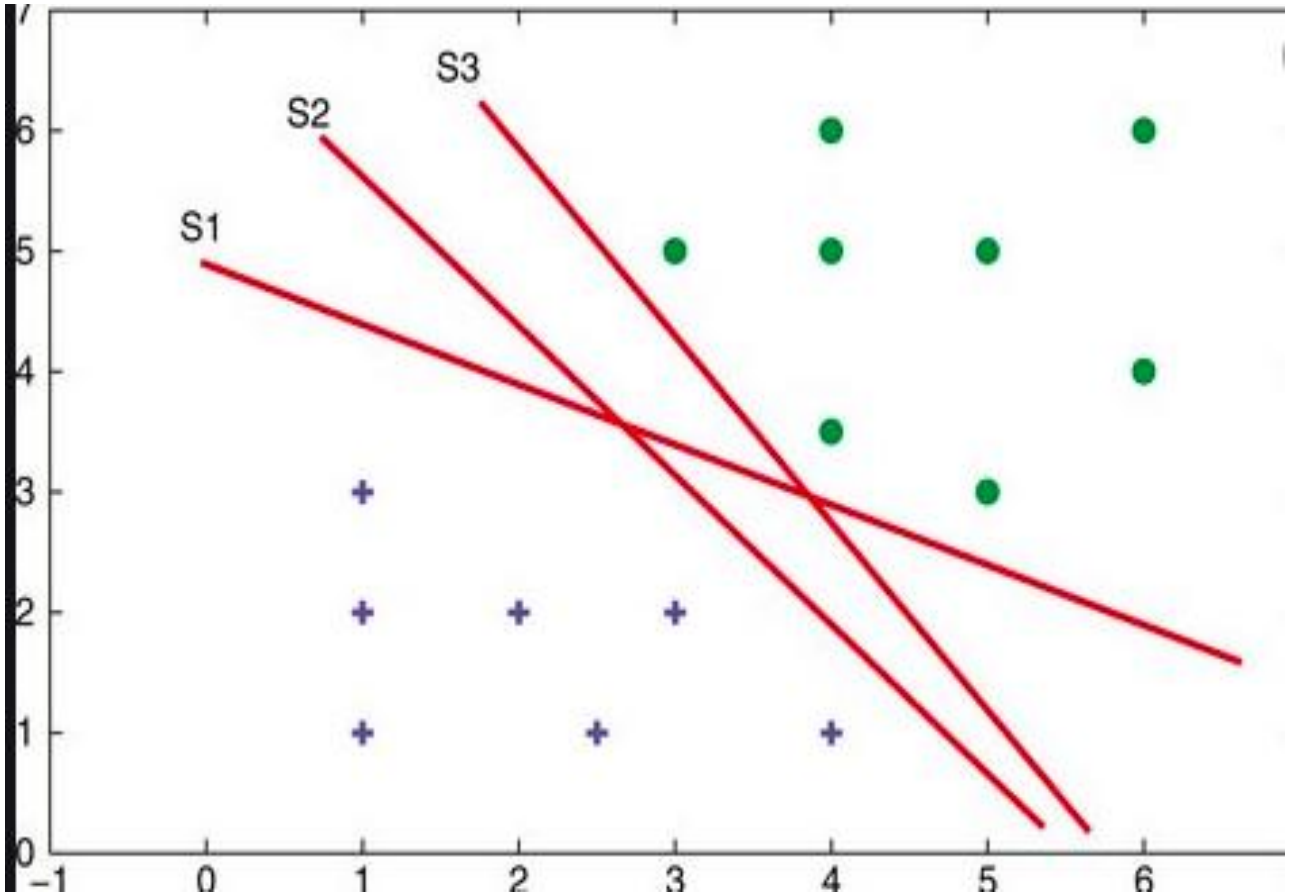
$$K(x, x') = exp(-\gamma|x - x'|^2)$$

  - Dimana **γ dan r are hyperparameters** dapat digunakan pada saat proses tunning.

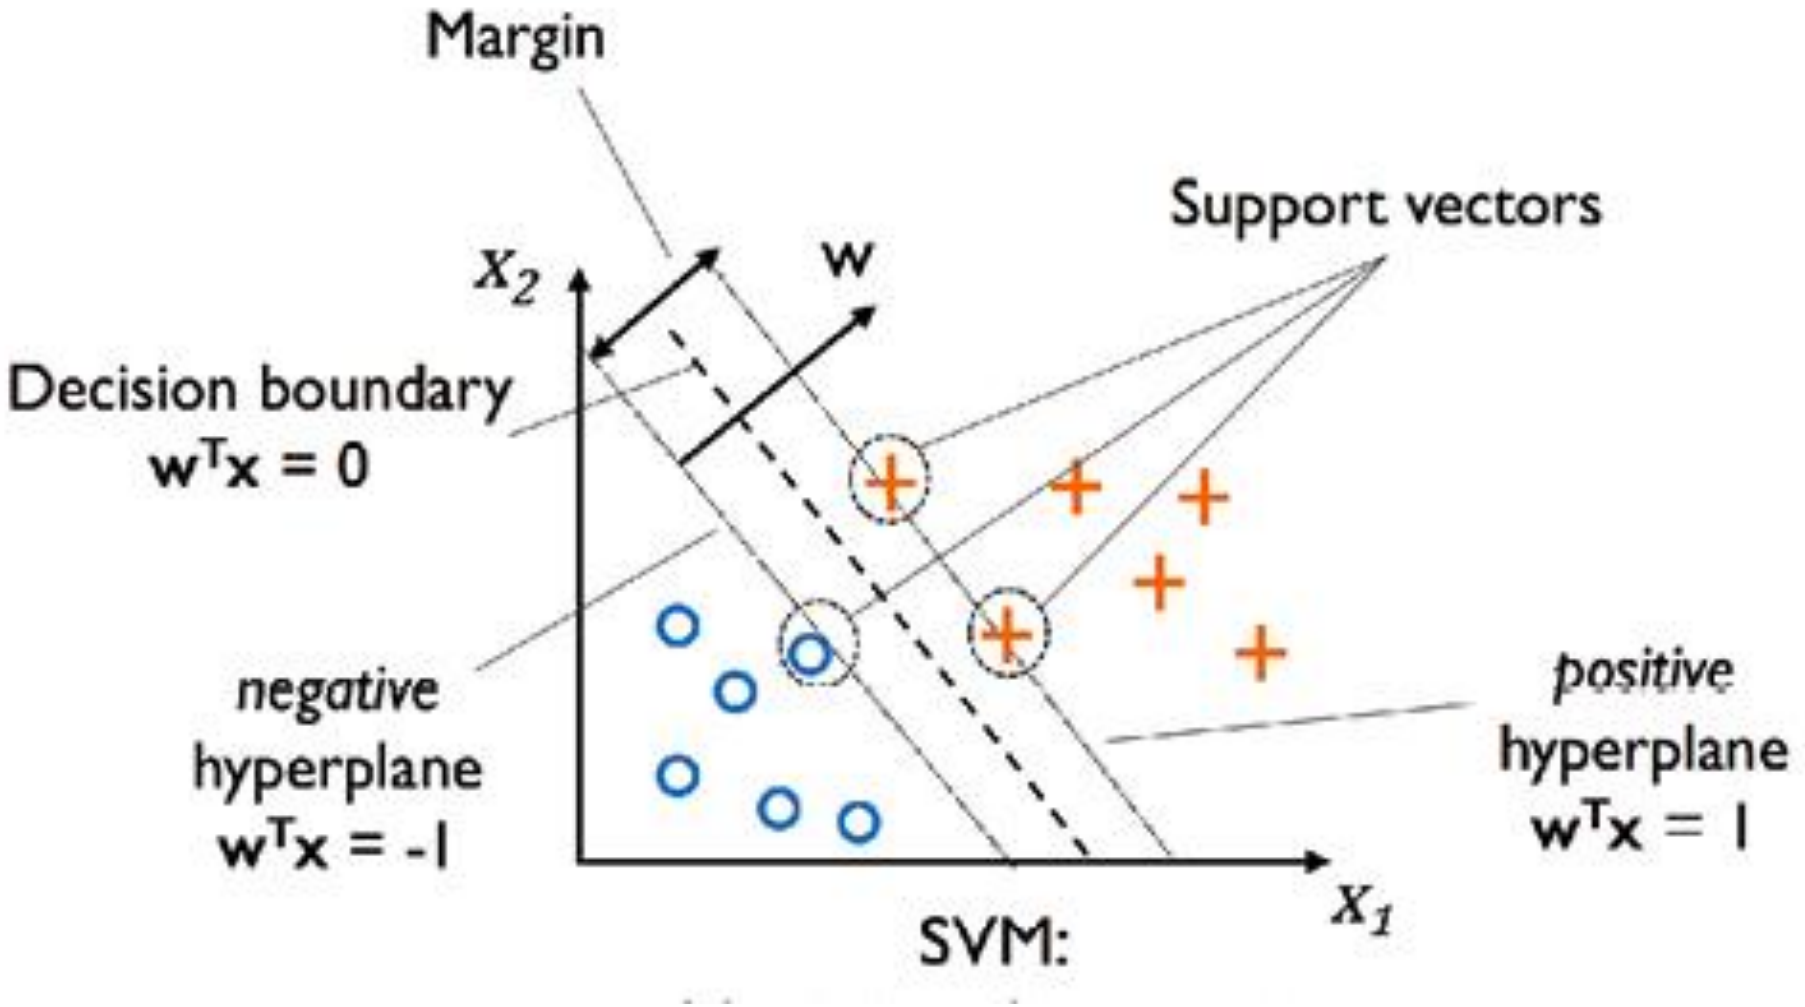
Maximum Margin dan Support Vector

Max Margin dan Support Vector





Hyperplane Mana yang Digunakan?

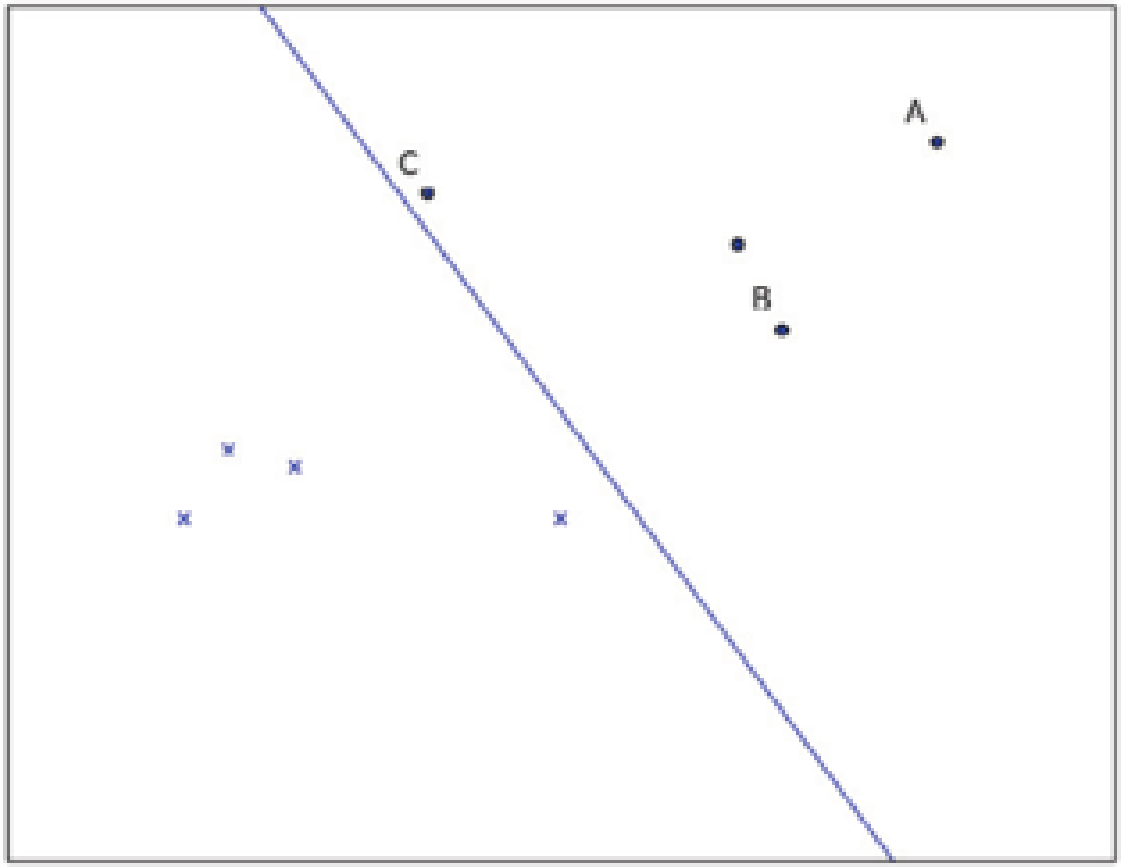


Mencari Hyperplane Terbaik

- Prediksi yang paling meyakinkan adalah untuk instance yang **berada paling jauh dari batas keputusan (decision boundary)**.
- Tingkat kepercayaan dari prediksi dapat diperkirakan menggunakan **margin fungsional (functional margin)**.

$$funct = \min y_i f(x_i)$$
$$f(x) = \langle w, x \rangle + b$$

  - y_i nilai kelas yang sesuai label (true).



Geometric Margin

- Lebar maksimum dari pita yang memisahkan **support vector**.
- Nilainya sama dengan **margin fungsional yang telah dinormalisasi**.
- Batas keputusan yang terbaik adalah yang memiliki **margin geometrik terbesar**.

$$min \frac{1}{2} \langle w, w \rangle$$

Dimana: $y_i(\langle w, x \rangle + b) \geq 1$

- Selanjutnya, untuk mengakomodasi **kernels**, menjadi:

$$W(\alpha) = \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \, \alpha_i y_i y_j K(x_i, x_i)$$

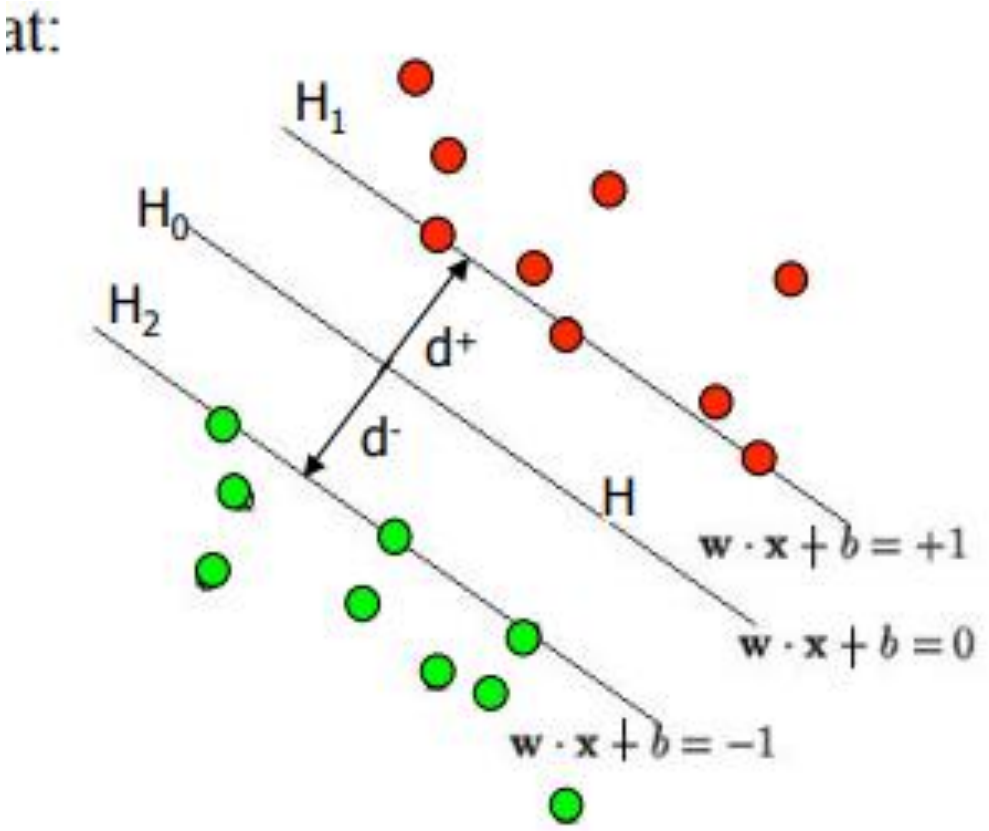
Dimana: $\sum_{i=1}^{n} \alpha_i \, y_i$=0; untuk: $\alpha_i \geq 1$

Mendefinisikan Hyperplane yang Memisahkan Kelas

- Bidang yang memisahkan kelas disebut **hyperplane** dengan bentuk: $w^T x + b = 0$, dimana:
  - $w \rightarrow$ bobot vektor
  - $x \rightarrow$ input vektor
  - $b \rightarrow$ bias
- Dimana
  - $w^T x + b \geq 0$ for $d_i = +1$
  - $w^T x + b < 0$ for $d_i = -1$

Hyperplane Pada Klasifikasi

- Definisikan hyperplanes H sehingga:
  - $w \cdot x_i + b \geq 1$ ketika $y_i = +1$
  - $w \cdot x_i + b \leq -1$ ketika $y_i = -1$
- H_1 dan H_2 adalah bidang (planes), dimana $H_1: w \cdot x_i + b = +1$ dan $H_2: w \cdot x_i + b = -1$
- Titik yang berada pada H_1 dan H_2 adalah acuan untuk **Support Vectors**. Bidang H_o adalah median dengan $w \cdot x_i + b = 0$
- $d+$ = jarak terdekat dengan titik (label) positif.
- $d-$ = jarak terdekat dengan titik (label) negatif.
- Margin adalah area dari $d+ + d-$.



Definisi d dan Max Margin

- **Margin of Separation ($\boldsymbol{d}$)** – jarak pemisah antara **hyperplane** dan titik data terdekat untuk vektor bobot ($\boldsymbol{w}$) dan bias ($\boldsymbol{b}$) tertentu.
- **Optimal Hyperplane (maximal margin)** – **hyperplane** khusus yang membuat **margin pemisahan ($\boldsymbol{d}$)** bernilai maksimum.


Thank You
Dankie
Salamat
faleminderit
Dhanyawaadh
Chezu ba
hvala
barka
Дзякуй
barka
Mauruuru
Ahéhee
Grazas
obrigado
kiitos
d'akujem
Daalų
takk fyri
Grazzi
miigwetch
ارك ش
hvala
eskerrik asko
Mèsi poutèt ou
köszönöm
ধন্যবাদ
trugéré
Welálin
Mahalo
Tak
Na gode
aitäh
dziękuję
hvala
děkuji
Grazzi
misaotra
manana
Grazzi
Merci
ačiū
Daalų
grazie
Grazias
gràcies
salamat
баярлалаа
Danke
köszönöm
misaotra
Merci
ačiū
Tak
ارك ش
hvala
Merci
Дзякуй
Xie xie
Dhanyabaad
ви благодариме
manana
Dankon
Go raibh maith agat
благодаря
Dhanyawaad
þakka þér
Daalų
manana
Grazzi
Merci
ačiū
Grazzi
Akeva
ありがとう
zikomo
Lorem ipsum dolor
matur nuwun
dank u
ام ش زا رک ش ت
Kamsahamnida
eskerrik asko
Sağ ol
Terima kasih